



# 人工智能 I






# 本周四实验课安排

|      |              |               |
|------|--------------|---------------|
| 周次   | 7            |               |
| 日期   | 2025/11/06   |               |
| 星期   | 星期四          |               |
| 时间   | 16:40-18:15  | 19:00-20:35   |
| 机房地点 | 中心楼实验室<br>D区 | 五五楼435<br>软实七 |
| 实验任务 | 对抗搜索         |               |

注意两个时间段是不同机房！请勿跑错！  
注意18:15机房电脑自动关机！请及时保存！





# 课程内容





# 本节课安排



- 回顾：基于搜索的问题求解
- 机器学习的数学基础
  - 矩阵论
  - 概率论
  - 信息论





# 本节课安排

- 回顾：基于搜索的问题求解
- 机器学习的数学基础
  - 矩阵论
  - 概率论
  - 信息论





# 基于搜索的问题求解

## ① 搜索问题（路径规划问题）

- 无信息搜索
  - 广度优先、深度优先、代价一致
- 有信息搜索
  - 贪婪算法、A\*算法

## ② 博弈问题

- 两位玩家、零和博弈
  - 极小极大算法
  - $\alpha - \beta$  剪枝



## ③ 约束满足问题

- 回溯搜索、及其改进方法：
  - 预处理（静态相容性检查）：节点相容、弧相容（AC-3算法）
  - 排序：
    - 变量排序：最少剩余值、度启发式
    - 值的排序：最少约束值
  - 推理（动态相容性检查）：前向检验、弧相容保持
  - 结构：独立子问题、树结构



# 本节课安排

- 回顾：基于搜索的问题求解
- 机器学习的数学基础
  - 矩阵论
  - 概率论
  - 信息论





# 矩阵与向量

## □ 矩阵

- $m * n$ 个数排成 $m$ 行 $n$ 列，简记为A

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

- 当 $m=n$ 时，则称A是n阶方阵

## □ 向量

- 一种特殊的矩阵

$$y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}$$



# 矩阵运算

## □ 矩阵加法

- 矩阵 $A$ 、 $B$ 均为 $m * n$ 矩阵，则 $m * n$ 矩阵 $C = A + B$ ，称为矩阵 $A$ 与 $B$ 的和

## □ 矩阵数乘

- 矩阵 $A$ 为 $m * n$ 矩阵， $k$ 为常数， $k$ 与矩阵 $A$ 每个元素相乘，称为数 $k$ 与矩阵 $A$ 的数乘

## □ 矩阵乘法

- 矩阵 $A$ 是 $m * n$ 矩阵，
- 矩阵 $B$ 是 $n * s$ 矩阵，
- $m * s$ 矩阵 $C = A \times B$  (or  $C = AB$ ) 称为矩阵 $A$ 与矩阵 $B$ 的乘法，其中，

$$c_{ij} = a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{in}b_{nj} = \sum_{k=1}^n a_{ik}b_{kj}$$



# 矩阵运算

□ 矩阵的乘法**不满足**交换律：

$$A \times B \neq B \times A$$

□ 矩阵的乘法满足结合律：

$$A \times (B \times C) = (A \times B) \times C$$



# 逆、转置

## □ 单位矩阵

- 从左上角到右下角的对角线（称为主对角线）上的元素均为1，其余全都为0，一般用I表示
- 性质

$$AA^{-1} = A^{-1}A = I$$

## □ 逆

- 如矩阵A是一个 $m * m$  矩阵（方阵），如果A可逆，则：

$$AA^{-1} = A^{-1}A = I$$



# 逆、转置

- $m * n$  矩阵A, 其转置矩阵大小为  $n * m$ , 其中的元素为:

$$(A^T)_{ij} = A_{ji}$$

- 基本性质

$$(A \pm B)^T = A^T \pm B^T$$

$$(A \times B)^T = B^T \times A^T \quad (AB)^T = B^T A^T$$

$$(A^T)^T = A$$



# 范数 (Norm)

- 在机器学习中，数据通常表示为向量或矩阵，范数是描述数据性质的重要指标
- 向量范数

- 0-伪范数，向量非0元素的个数：

$$\| \mathbf{x} \|_0 = \#\{i: x_i \neq 0\}$$

➤ 稀疏性

- 1-范数，向量元素绝对值之和

$$\| \mathbf{x} \|_1 = \sum_i |x_i|$$

➤ 通常用于替换0-伪范数。

- 2-范数，即向量元素的平方和再开方

$$\| \mathbf{x} \|_2 = \sqrt{\sum_i x_i^2}$$



# 范数 (Norm)

## □ 矩阵范数

### ■ 把矩阵 $A \in \mathbb{R}^{m \times n}$ 看成 $mn$ 维的向量

➤ F-范数，即矩阵元素的平方和再开方

$$\| A \|_F = \sqrt{\sum_{i,j} a_{ij}^2}$$

➤ 0-伪范数，即矩阵非0元素的个数，稀疏性

$$\| A \|_0 = \#\{(i,j) : a_{ij} \neq 0\}$$

➤ 1-范数，即矩阵元素的绝对值求和，替换0-伪范数

$$\| A \|_1 = \sum_{i,j} |a_{ij}|$$

➤  $\infty$ -范数，即矩阵元素的绝对值的最大值

$$\| A \|_\infty = \max_{i,j} |a_{ij}|$$



# 线性空间

- 所有 $m$ 维向量构成的集合记为 $\mathbb{R}^m$ , 称为欧式空间, 为特殊的线性空间
- 定义: 设 $\mathcal{V}$ 是非空集合,  $\mathbb{Q}$ 是数域。如果 $\mathcal{V}$ 满足如下10条性质, 则称 $\mathcal{V}$ 是数域 $\mathbb{Q}$ 上的线性空间
  - 加法: 对于 $x \in \mathcal{V}, y \in \mathcal{V}$ , 有唯一和 $x + y \in \mathcal{V}$  (封闭性)
    - 结合律:  $x + (y + z) = (x + y) + z$
    - 交换律:  $x + y = y + x$
    - 零元律: 存在零元素 $0$ , 使得 $x + 0 = x$
    - 负元律: 存在负元素 $-x$ , 使得 $x + (-x) = 0$
  - 乘法: 对于 $x \in \mathcal{V}, \alpha \in \mathbb{Q}$ , 有唯一积 $\alpha x \in \mathcal{V}$  (封闭性)
    - 数因子分配率:  $\alpha(x + y) = \alpha x + \alpha y$
    - 分配率:  $(\alpha + \beta)x = \alpha x + \beta x$
    - 结合律:  $\alpha(\beta x) = (\alpha\beta)x$
    - 恒等率:  $1x = x$



# 线性空间

- **性质**: 零元素是唯一的, 负元素也是唯一的

$$0\mathbf{x} = \mathbf{0}, (-1)\mathbf{x} = -\mathbf{x}$$

- **例1**:  $\mathbb{R}$ 是实数域 $\mathbb{R}$ 上的线性空间

- **例2**:  $\mathbb{R}^m$ 是实数域 $\mathbb{R}$ 上的线性空间

加法

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} + \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_m + y_m \end{bmatrix},$$

乘法

$$\alpha \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_m \end{bmatrix}$$

- **例3**:  $\mathcal{V} = \{\text{全体正实数}\}$ , 其加法与乘法定义分别为

$$\mathbf{x} \oplus \mathbf{y} = \mathbf{xy}, \alpha \otimes \mathbf{x} = \mathbf{x}^\alpha$$

则 $\mathcal{V}$ 是实数域 $\mathbb{R}$ 上的线性空间

- **例4**:  $\mathbb{R}^{m \times n}$ 是实数域 $\mathbb{R}$ 上的线性空间



# 线性相关性

- 线性组合： $\forall \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \in \mathcal{V}, \alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{Q}$ , 则  $\alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \dots + \alpha_n \mathbf{x}_n$  为元组  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$  的线性组合。
- 线性表示： $\mathcal{V}$  中的某个元素  $\mathbf{x}$  可表示为某元组的线性组合，则称  $\mathbf{x}$  可由该元组线性表示
- 线性相关：如果存在不全为 0 的数  $\alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{Q}$ , 使得
$$\alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \dots + \alpha_n \mathbf{x}_n = 0$$
则称元组  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$  线性相关，否则称其线性无关。

例1：线性空间  $\mathbb{R}$ ,  $\mathbf{x}_1 = 1, \mathbf{x}_2 = 2$  线性相关

例2：线性空间  $\mathbb{R}^2$

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \mathbf{x}_2 = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \mathbf{x}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$



# 基与坐标

- 设  $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_r$  是线性空间  $\mathcal{V}$  上的线性无关组，且  $\mathcal{V}$  中任意元素可由  $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_r$  线性表示，则  $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_r$  是  $\mathcal{V}$  的一组基，且维数  $\dim(\mathcal{V}) = r$ .
- 若元素  $\mathbf{x}$  在基  $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_r$  下的线性表示为

$$\mathbf{x} = x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \cdots + x_r \mathbf{a}_r$$

则称  $(x_1, x_2, \dots, x_r)$  为  $\mathbf{x}$  在该基（坐标系）下的坐标。

- $\mathbb{R}^2$  中的向量  $\mathbf{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$   
 $\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$  (1,1)  
 $\mathbf{a}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$  (1,0)

例： $\mathbb{R}^{m \times n}$  是实数域  $\mathbb{R}$  上的线性空间，它的一组基  $\{E_{ij}, i = 1, \dots, m, j = 1, \dots, n\}$

$$E_{ij} = \mathbf{e}_i \mathbf{e}_j^T$$



# 标准正交基

□ 设  $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_r$  是线性空间  $V$  的一组基，且

$$\langle \mathbf{a}_i, \mathbf{a}_j \rangle = \begin{cases} 0, & i \neq j, \\ 1, & i = j, \end{cases}$$

则  $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_r$  是线性空间  $V$  的一组标准正交基

例：  $\mathbb{R}^n$  的一组标准正交基：

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \dots, \mathbf{e}_n = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \\ 1 \end{bmatrix}$$



# 线性子空间

□ 定义：设  $\mathcal{V}_1$  是数域  $\mathbb{Q}$  上线性空间  $\mathcal{V}$  的非空子集，且对  $\mathcal{V}$  上的加法与数乘封闭：


- ① 如果  $x \in \mathcal{V}_1, y \in \mathcal{V}_1$ , 那么  $x + y \in \mathcal{V}_1$
- ② 如果  $x \in \mathcal{V}_1, \alpha \in \mathbb{Q}$ , 那么  $\alpha x \in \mathcal{V}_1$

则称  $\mathcal{V}_1$  是  $\mathcal{V}$  的（线性）子空间。

□ 子空间的生成：设  $x_1, x_2, \dots, x_n$  是线性空间  $\mathcal{V}$  上的  $n$  个元素，令  $\mathcal{V}_1$  为  $x_1, x_2, \dots, x_n$  所有可能的线性组合的集合， $\mathcal{V}_1 = \{\sum_{i=1}^n \alpha_i x_i\}$ 。那么  $\mathcal{V}_1$  是  $\mathcal{V}$  的子空间，称为由  $x_1, x_2, \dots, x_n$  张成的子空间，记为  $\text{span}\{x_1, x_2, \dots, x_n\}$

$$x_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, x_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

$$x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$





# 投影矩阵

## □ 问题：

- $\mathbf{x} = [x_1; x_2; \dots; x_d] \in \mathbb{R}^d$ ,  $\mathcal{V}$  为  $\mathbb{R}^d$  的  $r$  维子空间,  $\mathbf{u}_1, \dots, \mathbf{u}_r$  为  $\mathcal{V}$  的一组标准正交基。基矩阵:


$$\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_r] \in \mathbb{R}^{d \times r}, \mathbf{U}^T \mathbf{U} = I$$

- 寻找  $\mathcal{V}$  中与  $\mathbf{x}$  距离最小的点

$$\min_{\mathbf{y} \in \mathcal{V}} \| \mathbf{y} - \mathbf{x} \|_2$$

□ 解：设  $\mathbf{y} = \sum_{i=1}^r w_i \mathbf{u}_i = \mathbf{Uw}$ , 可得

$$\mathbf{w}^* = \mathbf{U}^T \mathbf{x}, \mathbf{y}^* = \mathbf{UU}^T \mathbf{x}$$



- $\mathbf{UU}^T \mathbf{x}$  为  $\mathbf{x}$  到子空间  $\mathcal{V}$  上的正交投影在原坐标系  $\mathbf{e}_1, \dots, \mathbf{e}_d$  下的坐标
- $\mathbf{UU}^T$  为子空间  $\mathcal{V}$  上的正交投影矩阵
- $\mathbf{U}^T \mathbf{x}$  为  $\mathbf{x}$  的正交投影在坐标系  $\mathbf{u}_1, \dots, \mathbf{u}_r$  下的坐标



# 特征值

- $A \in \mathbb{R}^{n \times n}$ , 如果存在常数 $\lambda$ 和非零向量 $x \in \mathbb{R}^n$ , 使得:

$$Ax = \lambda x$$

则称 $\lambda$ 为矩阵A的一个**特征值**(Eigenvalue),  $x$ 为矩阵A对应于特征值 $\lambda$ 的一个**特征向量**(Eigenvector)。

- 如果A有 $n$ 个线性无关的特征向量, 那么可对A做**特征值分解**(Eigenvalue Decomposition / ED)

$$A = Q\Lambda Q^{-1}$$

- Q是特征向量组成的**可逆矩阵**
- $\Lambda$ 是特征值组成的**对角矩阵**

$$\begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix}$$

- 不是所有矩阵都存在特征值分解, 即便存在, Q与 $\Lambda$ 中可能有复数
- 机器学习中, A通常是对称矩阵( $A^T = A$ ), 一定存在特征值分解, 且Q与 $\Lambda$ 一定取实数值



# 奇异值

- $A \in \mathbb{R}^{m \times n}$ , 则  $AA^T \in \mathbb{R}^{m \times m}$  与  $A^TA \in \mathbb{R}^{n \times n}$  均为半正定矩阵, 具有非负特征值。
- $AA^T$  的特征值的开方为  $A$  的左奇异值 (Singular Value)
- $AA^T$  的特征向量为  $A$  的左奇异向量 (Singular Vector)
- $A^TA$  的特征值的开方为  $A$  的右奇异值
- $A^TA$  的特征向量为  $A$  的右奇异向量
  - 左奇异值 = 右奇异值
- 任何情况下, 可对  $A$  做奇异值分解 (Singular Value Decomposition / SVD)

$$A = U\Sigma V^T$$

- $U \in \mathbb{R}^{m \times m}$  是左奇异向量组成的正交矩阵
- $V \in \mathbb{R}^{n \times n}$  是右奇异向量组成的正交矩阵
- $\Sigma \in \mathbb{R}^{m \times n}$  是奇异值组成的准对角矩阵

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 & 0 \\ 0 & 0 & \ddots & 0 & 0 \\ 0 & 0 & 0 & \ddots & 0 \end{bmatrix}_{m \times n}$$




# 关于SVD

- 非零奇异值的数目为矩阵的秩(rank)，也是矩阵行或列所张成的子空间的维度

- 行子空间
- 列子空间

$$A = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 1 & 2 & 3 & 4 \end{bmatrix}$$



- $A \in \mathbb{R}^{m \times n}, A = U\Sigma V^T, U^T U = I, V^T V = I$

- SVD:  $U \in \mathbb{R}^{m \times m}, UU^T = I; V \in \mathbb{R}^{n \times n}, VV^T = I; \Sigma \in \mathbb{R}^{m \times n}$  为准对角矩阵

- thin SVD (设  $m < n$ ):  $U \in \mathbb{R}^{m \times m}, UU^T = I; V \in \mathbb{R}^{n \times m}, VV^T \neq I; \Sigma \in \mathbb{R}^{m \times m}$  为对角矩阵



- skinny SVD (设  $r = \text{rank}(A)$ ):  $U \in \mathbb{R}^{m \times r}, UU^T \neq I; V \in \mathbb{R}^{n \times r}, VV^T \neq I; \Sigma \in \mathbb{R}^{r \times r}$  为对角矩阵

- $UU^T$  为列子空间的正交投影矩阵
- $VV^T$  为行子空间的正交投影矩阵



# 本节课安排

- 回顾：基于搜索的问题求解
- 机器学习的数学基础
  - 矩阵论
  - 概率论
  - 信息论






# 为什么需要概率？

- 计算机学科的大多数分支主要处理确定性问题
  - 程序员通常可以放心地假设CPU将完美地执行每一条指令
- 但是机器学习总是需应对**不确定性**(Uncertainty)
  - 随机性(Stochasticity, Nondeterministic)
  - 未知性(Unknown)
- 导致不确定性的因素
  - 本质上的随机性
    - 抛一枚硬币，正面朝上还是背面朝上？
  - 观测不完整
    - 纸牌游戏
  - 建模不完整
    - 下围棋



# 随机变量


- 随机变量 (Random Variable) 是能随机取不同值的变量
  - $X$  = 硬币哪面朝上
  - $R$  = 明天是否会下雨
  - $T$  = 开车上班需要的时间
- 通常使用大写字母表示随机变量
- 随机变量也有值域
  - $X \in \{\text{正面, 背面}\}$
  - $R \in \{\text{是, 否}\}$
  - $T \in [20, 60]$





# 概率分布

- 概率分布(Probability Distribution)是对随机变量呈现其每种可能状态(取值)的可能性的描述



| $T$ | $P$ |
|-----|-----|
| 正面  | 0.5 |
| 背面  | 0.5 |

| $W$ | $P$ |
|-----|-----|
| 晴天  | 0.6 |
| 雨天  | 0.1 |
| 雾   | 0.3 |



# 概率质量函数(PMF)

## □ 概率质量函数(Probability Mass Function, PMF)

- 设随机变量 $X$ 的值域为 $\mathcal{D}$
- PMF:  $P(X = x)$ 表示 $X$ 取值为 $x$ 的概率, 简记为 $P(x)$

- $\square \sum_{x \in \mathcal{D}} P(x) = 1$

- $\square \forall x \in \mathcal{D}, 0 \leq P(x) \leq 1$

- $X \sim P$  表示 $X$ 服从分布 $P$ , 即 $X$ 的PMF为 $P(x)$

- E. g., 均匀分布 (Uniform Distribution)

- $\triangleright$  随机变量 $X$ 的值域为 $\mathcal{D} = \{x_1, x_2, \dots, x_k\}$

$$P(x_i) = \frac{1}{k}, i = 1, \dots, k$$

| $T$ | $P$ |
|-----|-----|
| 正面  | 0.5 |
| 背面  | 0.5 |



# 联合分布

- 多个随机变量的概率分布称为**联合分布** (Joint Probability Distribution)

- $P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$  表示  $X_1$  取值为  $x_1$ 、且  $X_2$  取值为  $x_2$ 、……、且  $X_n$  取值为  $x_n$  的概率，简记为  $P(x_1, x_2, \dots, x_n)$

| $T$ | $W$ | $P$ |
|-----|-----|-----|
| 炎热  | 晴天  | 0.4 |
| 炎热  | 雨天  | 0.1 |
| 寒冷  | 晴天  | 0.2 |
| 寒冷  | 雨天  | 0.3 |

- $(X_1, \dots, X_n)$  可看做是一个多元随机变量  $X$



# 概率密度函数(PDF)

- PMF是针对离散随机变量
- 概率密度函数(Probability Density Function, PDF)
  - 设连续随机变量 $X$ 的值域为 $\mathcal{D}$
  - $X$ 的概率分布由PDF描述
    - $\forall x \in \mathcal{D}, P(x) \geq 0$ 
      - 注意:  $P(x)$ 可以大于1, 不是 $X$ 取值为 $x$ 的概率.
    - $\int_{\mathcal{S}} P(x) dx$ 表示 $X$ 的取值属于某集合 $\mathcal{S}$ 的概率 ( $\mathcal{S} \subseteq \mathcal{D}$ )
      - $P(X = x) = \int_x^x P(t) dt = 0.$
    - $\int_{\mathcal{D}} P(x) dx = 1$

- e. g., 均匀分布 (Uniform Distribution)

- $\mathcal{D} = [a, b], b > a$

$$P(x) = \frac{1}{b - a}$$





# 边缘分布

- 一组随机变量的子集的分布称为边缘分布 (Marginal Probability Distribution)

- 边缘分布也是一个概率分布
- 比如, 已知  $P(x, y)$  求  $P(x)$

$$P(x) = \sum_y P(x, y) \text{ or } P(x) = \int P(x, y) dy.$$

| $T$ | $W$ | $P$ |
|-----|-----|-----|
| 炎热  | 晴天  | 0.4 |
| 炎热  | 雨天  | 0.1 |
| 寒冷  | 晴天  | 0.2 |
| 寒冷  | 雨天  | 0.3 |

$$P(t) = \sum_s P(t, s)$$

| $T$ | $P$ |
|-----|-----|
| 炎热  | 0.5 |
| 寒冷  | 0.5 |

$$P(s) = \sum_t P(t, s)$$

| $W$ | $P$ |
|-----|-----|
| 晴天  | 0.6 |
| 雨天  | 0.4 |



# 练习

$P(X, Y)$

| X  | Y  | P   |
|----|----|-----|
| +X | +y | 0.2 |
| +X | -y | 0.3 |
| -X | +y | 0.4 |
| -X | -y | 0.1 |

$$P(x) = \sum_y P(x, y)$$


$P(X)$

| X  | P |
|----|---|
| +X |   |
| -X |   |

$$P(y) = \sum_x P(x, y)$$

$P(Y)$

| Y  | P |
|----|---|
| +y |   |
| -y |   |





# 事件 (Event)

- 随机变量 $X$ 的值域为 $\mathcal{D}$
- 值域 $\mathcal{D}$ 的子集 $\mathcal{E}$ 称为一个**事件**,  
 $X \in \mathcal{E}$ 表示事件 $\mathcal{E}$ 发生
- 事件发生的概率
  - $P(\mathcal{E}) = \sum_{x \in \mathcal{E}} P(x)$
  - $\int_{\mathcal{E}} P(x) dx$
- 练习: 通过联合分布, 计算事件发生的概率
  - 炎热并且是晴天的概率
  - 炎热或者是晴天的概率
  - 炎热的概率

|     |     | $P(T, W)$ |
|-----|-----|-----------|
| $T$ | $W$ | $P$       |
| 炎热  | 晴天  | 0.4       |
| 炎热  | 雨天  | 0.1       |
| 寒冷  | 晴天  | 0.2       |
| 寒冷  | 雨天  | 0.3       |



# 条件概率

- 条件概率 (Conditional Probability) : 在事件 $\mathcal{A}$ 发生的条件下, 事件 $B$ 发生的概率, 记为 $P(B|\mathcal{A})$ 
  - 条件概率公式

$$P(B|\mathcal{A}) = \frac{P(\mathcal{A}, B)}{P(\mathcal{A})}$$
$$P(y|x) = \frac{P(x, y)}{P(x)}$$

$P(T, W)$

| $T$ | $W$ | $P$ |
|-----|-----|-----|
| 炎热  | 晴天  | 0.4 |
| 炎热  | 雨天  | 0.1 |
| 寒冷  | 晴天  | 0.2 |
| 寒冷  | 雨天  | 0.3 |

$$P(W = \text{晴天} | T = \text{寒冷}) = \frac{P(W = \text{晴天}, T = \text{寒冷})}{P(T = \text{寒冷})} = \frac{0.2}{0.5} = 0.4$$

$$\begin{aligned} &= P(W = \text{晴天}, T = \text{寒冷}) + P(W = \text{雨天}, T = \text{寒冷}) \\ &= 0.2 + 0.3 = 0.5 \end{aligned}$$



# 练习

$P(X, Y)$

| X  | Y  | P   |
|----|----|-----|
| +x | +y | 0.2 |
| +x | -y | 0.3 |
| -x | +y | 0.4 |
| -x | -y | 0.1 |

□  $P(+x|+y) = ?$

□  $P(-x|+y) = ?$

□  $P(-y|+x) = ?$



# 贝叶斯法则 (Bayes' Rule)

- 对两个变量的联合分布进行条件概率分解的两种方法：

$$P(x, y) = P(x|y)P(y) = P(y|x)P(x)$$

- 两边同除，得到：

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}$$

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$

- 有什么用？

- 反向构建条件
- 通常一个计算比较麻烦，但另一个计算相对简单。比如：  
假设已知 $P(\text{抽烟})$ 与 $P(\text{肺癌})$ ，求 $P(\text{肺癌}|\text{抽烟})$

$$P(\text{肺癌}|\text{抽烟}) = \frac{P(\text{抽烟}|\text{肺癌})P(\text{肺癌})}{P(\text{抽烟})}$$





# 链式法则(Chain Rule)

---

□ 三个随机变量 $A, B, C$ :

$$P(a, b, c) = P(a|b, c)P(b, c)$$

$$P(b, c) = P(b|c)P(c)$$

$$P(a, b, c) = P(a|b, c)P(b|c)P(c)$$

□  $n$ 个随机变量 $X_1, \dots, X_n$

$$P(x_1, x_2, \dots, x_n) = P(x_1) \prod_{i=2}^n P(x_i|x_1, \dots, x_{i-1})$$



# 独立与条件独立

- 事件 $\mathcal{A}$ 与 $\mathcal{B}$ 独立(Independence), 记为 $\mathcal{A} \perp \mathcal{B}$

$$P(\mathcal{A}, \mathcal{B}) = P(\mathcal{A})P(\mathcal{B})$$

$$P(\mathcal{A}|\mathcal{B}) = P(\mathcal{A}), P(\mathcal{B}|\mathcal{A}) = P(\mathcal{B})$$

- 连续随机变量 $X$ 与 $Y$ 独立, 记为 $X \perp Y$

$$P(x, y) = P(x)P(y), \forall x, y$$

- 事件 $\mathcal{A}$ 与 $\mathcal{B}$ 在事件 $\mathcal{C}$ 发生的条件下独立 (Conditional Independence), 记为 $\mathcal{A} \perp \mathcal{B}|\mathcal{C}$

$$P(\mathcal{A}, \mathcal{B}|\mathcal{C}) = P(\mathcal{A}|\mathcal{C})P(\mathcal{B}|\mathcal{C})$$

$$P(\mathcal{A}|\mathcal{B}, \mathcal{C}) = P(\mathcal{A}|\mathcal{C}), P(\mathcal{B}|\mathcal{A}, \mathcal{C}) = P(\mathcal{B}|\mathcal{C})$$

- 连续随机变量 $X$ 与 $Y$ 在 $Z$ 给定的条件下独立, 记为 $X \perp Y|Z$

$$P(x, y|z) = P(x|z)P(y|z), \forall x, y, z$$

- 独立与条件独立之间的关系:

- 独立不意味着条件独立, e. g., 抛骰子
- 条件独立不意味着独立, e. g., 马尔科夫链



# 期望、方差、协方差

□ 随机变量 $X$ 的函数 $f(X)$ , e. g. ,  $f(X) = X$ 。如何描述 $f(X)$ ?

■ 期望(Expectation):

$$\mathbf{E}_{X \sim P}[f(X)] = \sum_x f(x)P(x) \text{ or } \int f(x)P(x)dx$$

➤ 简记:  $\mathbf{E}_X[f(X)], \mathbf{E}[f(X)]$

■ 方差(Variance):

$$\mathbf{Var}[f(X)] = \mathbf{E}[(f(X) - \mathbf{E}[f(X)])^2]$$

□ 随机变量 $X$ 的函数 $f(X)$ , 随机变量 $Y$ 的函数 $g(Y)$

■ 协方差(Covariance)

$$\mathbf{Cov}[f(X), g(Y)] = \mathbf{E}[(f(X) - \mathbf{E}[f(X)])(g(Y) - \mathbf{E}[g(Y)])]$$

■  $\mathbf{Var}[f(X)] = \mathbf{Cov}[f(X), f(X)]$



# 练习

- 计算**E**[ $T$ ], **E**[ $W$ ]
- 计算**Var**[ $T$ ], **Var**[ $W$ ]
- 计算**Cov**[ $T, W$ ]

| $P(T, W)$ |   |     |
|-----------|---|-----|
| T         | W | P   |
| 1         | 1 | 0.4 |
| 1         | 0 | 0.1 |
| 0         | 1 | 0.2 |
| 0         | 0 | 0.3 |

$$\mathbf{E}[f(X)] = \sum_x f(x)P(x)$$

$$\mathbf{Var}[f(X)] = \mathbf{E}[(f(X) - \mathbf{E}[f(X)])^2]$$

$$\mathbf{Cov}[f(X), g(Y)] = \mathbf{E}[(f(X) - \mathbf{E}[f(X)])(g(Y) - \mathbf{E}[g(Y)])]$$



# 常用概率分布

## □ 伯努利分布(Bernoulli Distribution)

- $\mathcal{D} = \{0, 1\}$
- PMF:

$$P(X = 1) = \rho \in [0,1]$$

$$P(X = 0) = 1 - \rho$$

$$P(x) = \rho^x(1 - \rho)^{1-x}$$

$$\text{E}(X) = \rho$$

$$\text{Var}(X) = \rho(1 - \rho)$$



# 常用概率分布


- 多努利分布(Multinoulli Distribution), 也称分类分布(Categorical Distribution)

- $\mathcal{D} = \{x_1, \dots, x_k\}$

- PMF:

$$P(X = x_i) = \rho_i \geq 0, i = 1, \dots, k$$
$$\sum_{i=1}^k \rho_i = 1.$$

- 主要用于类别建模, 无需关注 $x_i$ 的真实取值, 无需计算期望与方差





# 常用概率分布


- 正态分布(Normal Distribution), 也称高斯分布(Gaussian Distribution)

- $\mathcal{D} = \mathbb{R}$

- PDF:

简记为:  $\mathcal{N}(\mu, \sigma)$

$$P(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$
$$\mathbf{E}[X] = \mu, \mathbf{Var}[X] = \sigma^2.$$



标准正态分布:


- $\mu = 0$
- $\sigma = 1$



# 常用概率分布


## □ 指数分布(Exponential Distribution)

- $\mathcal{D} = \mathbb{R}^+$
- PDF:  $P(x) = \lambda \exp(-\lambda x), x \geq 0$
- $E[X] = 1/\lambda, \text{Var}[X] = 1/\lambda^2$
- 简记为:  $\text{Exp}(\lambda)$



## □ 拉普拉斯分布(Laplace Distribution)

- $\mathcal{D} = \mathbb{R}$
- PDF:  $P(x) = \frac{1}{2\gamma} \exp\left(-\frac{|x-\mu|}{\gamma}\right)$
- $E[X] = \mu, \text{Var}[X] = 2\gamma^2$
- 简记为:  $\text{Laplace}(\mu, \gamma)$





# 常用概率分布

## □ 经验分布(Empirical Distribution)

- $\mathcal{D} = \mathbb{R}^d$
- 把数据看做随机变量  $X \in \mathbb{R}^d$
- 设有  $n$  个数据样本  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n \in \mathbb{R}^d$
- PDF:

$$P(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \delta(\mathbf{x} - \mathbf{x}_i),$$



- 狄拉克  $\delta$  函数(Dirac Delta Function):

$$\delta(\mathbf{x}) = \begin{cases} 1, & \text{if } \mathbf{x} = \mathbf{0}, \\ 0, & \text{otherwise.} \end{cases}$$



# 本节课安排


- 回顾：基于搜索的问题求解
- 机器学习的数学基础
  - 矩阵论
  - 概率论
  - 信息论





# 信息论 (Information Theory)

- 应用数学的分支
- 主要关注如何量化信号（数据）中的信息量
- 信息论有什么用处？
  - （定量地）刻画概率分布的性质
  - 刻画概率分布之间的相似性
- 在机器学习中：
  - 矩阵论是为了对数据的确定性部分进行描述（主体）
  - 概率论与信息论是对数据的不确定性部分进行描述（重要补充）





# 熵 (Entropy)

□ 如何量化信号（数据）中的信息量？

■ 基本准则：

✓ 事件发生的概率越小，包含的信息量越大（不确定量）

➢ 今天早上太阳出来了

➢ 今天早上发生日全食

✓ 独立事件的信息量可累加

□ 自信息量(Self-Information)：一个事件  $X = x$  的信息量为：

$$I(x) = \log \frac{1}{P(x)} = -\log P(x)$$

□ 熵(Entropy)：随机变量  $X$  的概率分布为  $P$ ，其信息量（不确定量）为：

$$H(X) = \mathbf{E}[I(x)] = -\mathbf{E}[\log P(x)] = -\sum P(x) \log P(x)$$


■ 也记为  $H(P)$ ，描述概率分布的性质



# 概率分布的熵

## □ 伯努利分布：

$$H(X) = -\mathbf{E}[\log P(x)] = -\rho \log \rho - (1 - \rho) \log(1 - \rho)$$



## □ 正态分布：

$$\begin{aligned} H(X) &= -\mathbf{E}[\log P(x)] = \\ &= - \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \log\left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)\right) dx \\ &= \frac{1}{2} + \frac{1}{2} \log(2\pi\sigma^2) \end{aligned}$$




# KL散度

- 假设得到了随机变量 $X$ 的两个分布 $P(x)$ 与 $Q(x)$ , 如何衡量这两个分布之间的差异性?
- **KL散度**(Kullback-Leibler Divergence):

$$D_{KL}(P||Q) = \mathbf{E}_{X \sim P} \log \left( \frac{P(x)}{Q(x)} \right) = \mathbf{E}_{X \sim P} [\log(P(x)) - \log(Q(x))]$$

- $D_{KL}(P||Q) \geq 0$ , 取0当且仅当 $P = Q$
- $D_{KL}(P||Q) \neq D_{KL}(Q||P)$





# 交叉熵

- 交叉熵(Cross Entropy):

$$H(P, Q) = -\mathbf{E}_{X \sim P} \log(Q(x))$$

- 离散变量:

$$H(P, Q) = - \sum_x P(x) \log(Q(x))$$

- 连续变量:

$$H(P, Q) = - \int_x P(x) \log(Q(x)) dx$$

- $H(P, Q) = H(P) + D_{KL}(P||Q)$

- 寻找与已知分布  $P$  最接近的分布  $Q$ :

$$\min_Q D_{KL}(P||Q) \text{ 等价于 } \min_Q H(P, Q)$$

- 机器学习中,  $P$  通常 是真实标记的分布,  $Q$  为模型的预测标记分布



# 练习

- 在人工智能问题中，经常会出现如下优化问题

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_2^2$$

其中  $\mathbf{A} \in \mathbb{R}^{m \times n}$ 、 $\mathbf{b} \in \mathbb{R}^m$  与  $\lambda > 0$  已知。

请写出求解  $\mathbf{x}$  的推导步骤。

- 小明所在的社区爆发了流感，社区中5万名人员共有1万人被感染。经统计得知，5万名人员中有1.2万人有发烧症状，1万名感染者中有8千人有发烧症状。某天，小明发烧了，非常想知道自己有没有感染流感。请运用概率论知识，估算出小明感染流感的概率。