



人工智能 I

杨杰

yangjie@seu.edu.cn

2025/11/17, 五四楼-303, 9:50~11:25



本周四实验课安排

周次	9	
日期	2025/11/20	
星期	星期四	
时间	16:40-18:15	19:00-20:35
机房地点	中心楼实验室 D区	五五楼435 软实七
实验任务	支持向量机	

注意两个时间段是不同机房！请勿跑错！
注意18:15机房电脑自动关机！请及时保存！



本节课安排

□ 监督学习：

- 线性回归
- 对率回归
- 支持向量机
- 决策树
- 随机森林
- 贝叶斯分类器
- 感知机与神经网络





本节课安排


□ 监督学习：

- 线性回归
- 对率回归
- 支持向量机
- 决策树
- 随机森林
- 贝叶斯分类器
- 感知机与神经网络





线性模型



线性模型(linear model)试图学得一个通过属性的**线性组合**来进行预测的函数

$$f(x) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$$

向量形式: $f(x) = w^T x + b$

简单、基本、可理解性好




一元(uni-variate)线性回归

- 示例：根据年龄预测小孩身高

年龄 (月)	身高 (cm)
12	75
24	88
36	98
48	101
...	...

给定一组历史数据，如何预测未来身高？

解决方法：用一条直线去尽量准确的拟合这些数据，然后如果有新的输入过来，我们可以在将直线上这个点对应的值返回。





一元(uni-variate)线性回归

□ 形式化描述

■ 训练数据

$$\begin{aligned} & (x_1, y_1) \\ & (x_2, y_2) \\ & \dots \\ & (x_m, y_m) \end{aligned}$$

年龄 (月)	身高 (cm)
12	75
24	88
36	94
48	101
...	...

■ 预测模型

$$f(x) = wx + b, \quad w \in \mathbb{R}, b \in \mathbb{R}$$

■ 学习算法

最小化MSE，有： $(w^*, b^*) =$

$$\arg \min_{w,b} \sum_{i=1}^m (y_i - wx_i - b)^2$$

\downarrow

$$E(w, b)$$



一元(uni-variate)线性回归

分别对 w 和 b 求导：

$$\frac{\partial E(w, b)}{\partial w} = 2 \left(w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b)x_i \right)$$

$$\frac{\partial E(w, b)}{\partial b} = 2 \left(mb - \sum_{i=1}^m (y_i - wx_i) \right)$$

令导数为0, 得到闭式(closed-form)解：

$$w^* = \frac{\sum_{i=1}^m y_i(x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} (\sum_{i=1}^m x_i)^2}$$

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

$$b^* = \frac{1}{m} \sum_{i=1}^m (y_i - w^*x_i)$$



多元(multi-variate)线性回归

□ 数据

$$(\mathbf{x}_1, y_1)$$

$$(\mathbf{x}_2, y_2)$$

.....

$$(\mathbf{x}_m, y_m)$$

$$\mathbf{x}_i = \begin{bmatrix} x_{1i} \\ x_{2i} \\ \vdots \\ x_{di} \end{bmatrix} \in \mathbb{R}^d, y_i \in \mathbb{R}$$

□ 预测模型

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b, \quad \mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix} \in \mathbb{R}^d, b \in \mathbb{R}$$

□ 学习算法

$$(\mathbf{w}^*, b^*) = \arg \min_{(\mathbf{w}, b)} \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2$$



多元(multi-variate)线性回归

□ 推导过程

$$X = \begin{bmatrix} \mathbf{x}_1 & \cdots & \mathbf{x}_m \\ 1 & \cdots & 1 \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ x_{d1} & x_{d2} & \cdots & x_{dm} \\ 1 & 1 & \cdots & 1 \end{bmatrix} \in \mathbb{R}^{(d+1) \times m}$$

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix} \in \mathbb{R}^m$$

$$\tilde{\mathbf{w}} = \begin{bmatrix} \mathbf{w} \\ b \end{bmatrix} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \\ b \end{bmatrix} \in \mathbb{R}^{d+1}$$

$$\sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2 = \| X^T \tilde{\mathbf{w}} - \mathbf{y} \|_2^2$$

令导数为0, 得: $XX^T \tilde{\mathbf{w}} = X\mathbf{y}$

- 若 XX^T 满秩或正定, 则 $\tilde{\mathbf{w}}^* = (XX^T)^{-1}X\mathbf{y}$
- 若 XX^T 不满秩, 则存在多个解, 需引入**正则化**(regularization)



正则化 (regularization)

□ 前面所接触的学习模型：

$$\min_f \sum_{i=1}^m \ell(f(\mathbf{x}_i), y_i)$$

□ 更一般的学习模型：

λ : 超参数

$$\min_f \sum_{i=1}^m \ell(f(\mathbf{x}_i), y_i) + \lambda \Omega(f)$$

经验风险
(empirical risk)
描述模型与训练
数据的契合程度

结构风险
(structural risk)
描述模型本身
的某些性质

□ 正则化可理解为“罚函数法”

- 通过对不希望的结果施以惩罚，使得优化过程趋向于希望目标
- 归纳偏好



带正则化的多元线性回归

□ 2-范数正则化：

$$\tilde{\mathbf{w}}^* = \arg \min_{\tilde{\mathbf{w}}} \| X^T \tilde{\mathbf{w}} - \mathbf{y} \|_F^2 + \lambda \| \tilde{\mathbf{w}} \|_2^2$$

$$\tilde{\mathbf{w}}^* = (X X^T + \lambda I)^{-1} X \mathbf{y}$$


$$X X^T = U \begin{bmatrix} \sigma_1 & 0 & 0 & 0 \\ 0 & \sigma_2 & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & \sigma_{d+1} \end{bmatrix} U^T$$

$$X X^T + \lambda I = U \begin{bmatrix} \sigma_1 + \lambda & 0 & 0 & 0 \\ 0 & \sigma_2 + \lambda & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & \sigma_{d+1} + \lambda \end{bmatrix} U^T$$



广义线性回归

- 线性模型无法拟合非线性数据（欠拟合）



令预测值逼近 y 的衍生物？


对数线性回归

$$\ln y = \mathbf{w}^T \mathbf{x} + b$$

等价于用 $e^{\mathbf{w}^T \mathbf{x} + b}$ 逼近 y

- 广义线性回归

$$y = g^{-1}(\mathbf{w}^T \mathbf{x} + b)$$



单调可微的 联系函数(link function)



本节课安排

□ 监督学习：

- 线性回归
- 对率回归
- 支持向量机
- 决策树
- 随机森林
- 贝叶斯分类器
- 感知机与神经网络






二分类问题

年龄 (月)	偏高 or 偏矮
12	0
24	1
36	1
48	0
...	...

直接应用线性回归模型，效果差



线性回归模型产生的输出： $z = \mathbf{w}^T \mathbf{x} + b$

期望输出： $y \in \{0,1\}$ or $\{-1,1\}$

$$y \in \{-, +\}$$

找 z 和 y 的
联系函数



用于分类的联系函数

线性回归模型产生的输出: $z = \mathbf{w}^T \mathbf{x} + b$

期望输出: $y \in \{0,1\}$

} 找 z 和 y 的
联系函数

单位阶跃函数

(unit-step function):

$$y = \begin{cases} 0, & z < 0 \\ 0.5, & z = 0 \\ 1, & z > 0 \end{cases}$$

性质不好,
需找“替代函数”
(surrogate function)


对数几率函数

(logistic function)

简称对率函数

$$y = \frac{1}{1 + e^{-z}}$$

单调可微、任意阶可导





对率回归

对率回归(Logistic Regression)，也称逻辑回归：
以对率函数为联系函数的线性回归

$$y = \frac{1}{1 + e^{-z}} \quad \longrightarrow \quad y = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

注意：对率回归是分类算法

可变形为：

$$\log \frac{y}{1 - y} = \mathbf{w}^T \mathbf{x} + b$$

几率(odds), 反映了 \mathbf{x} 作为正例的相对可能性

会出现溢出

计算仍然存在困难，直接应用线性回归算法不可取！



求解思路

将类标 $y \in \{0,1\}$ 看作类后验概率值 $y = P(c = +|\mathbf{x})$

预测模型: $P_{\mathbf{w}}(c = +|\mathbf{x}) = \frac{1}{1+e^{-(\mathbf{w}^T \mathbf{x} + b)}}$

于是, 可使用 “极大似然估计法”

(maximum likelihood method)

已知某组独立同分布样本满足某概率分布 $P_{\boldsymbol{\theta}}(\mathbf{a})$, 但是其中参数 $\boldsymbol{\theta}$ 未知。极大似然估计是参数估计的方法之一:
寻找参数使这组样本出现的概率最大!

$$\max_{\boldsymbol{\theta}} \prod_{i=1}^m P_{\boldsymbol{\theta}}(\mathbf{a}_i) \quad \longleftrightarrow \quad \max_{\boldsymbol{\theta}} \log \left(\prod_{i=1}^m P_{\boldsymbol{\theta}}(\mathbf{a}_i) \right)$$

$$\max_{\boldsymbol{\theta}} \sum_{i=1}^m \log(P_{\boldsymbol{\theta}}(\mathbf{a}_i))$$



求解思路

记 $\mathbf{w} = [\mathbf{w}; b]$, $\mathbf{x} = [\mathbf{x}; 1]$, 于是

$$P_{\mathbf{w}}(c = +|\mathbf{x}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = \frac{e^{\mathbf{w}^T \mathbf{x}}}{1 + e^{\mathbf{w}^T \mathbf{x}}}$$

$$P_{\mathbf{w}}(c = -|\mathbf{x}) = 1 - P(c = +|\mathbf{x}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x}}}$$

$$\max_{\mathbf{w}} \sum_{i=1}^m \log(P_{\mathbf{w}}(c_i | \mathbf{x}_i)) \quad \longleftrightarrow \quad \min_{\mathbf{w}} - \sum_{i=1}^m \log(P_{\mathbf{w}}(c_i | \mathbf{x}_i))$$

$$\min_{\mathbf{w}} \sum_{i=1}^m \left(-y_i \mathbf{w}^T \mathbf{x}_i + \log(1 + e^{\mathbf{w}^T \mathbf{x}_i}) \right)$$

注意: $y_i \in \{0, 1\}$

高阶可导连续凸函数, 可用经典的数值优化方法, 如梯度下降法/牛顿法



本节课安排

□ 监督学习：

- 线性回归
- 对率回归
- 支持向量机
- 决策树
- 随机森林
- 贝叶斯分类器
- 感知机与神经网络






线性模型做分类

□ 对率回归：

- 通过“联系函数”，把分类问题转化为回归问题

□ 如何直接做分类？

在样本空间中寻找一个超平面，将不同类别的样本分开



超平面： \mathbb{R}^d 的 $d - 1$ 维仿射子空间

$$\{\mathbf{x} | \mathbf{w}^T \mathbf{x} + b = 0, \mathbf{x} \in \mathbb{R}^d\}$$

正类： $\{\mathbf{x} | \mathbf{w}^T \mathbf{x} + b > 0, \mathbf{x} \in \mathbb{R}^d\}$

负类： $\{\mathbf{x} | \mathbf{w}^T \mathbf{x} + b < 0, \mathbf{x} \in \mathbb{R}^d\}$




线性模型做分类

- 假设类标为 $\{-1, +1\}$ 且训练数据线性可分，那么所有能正确划分训练数据的超平面可表示为：

$$\left. \begin{array}{l} \text{正样本} (y_i = 1): \mathbf{w}^T \mathbf{x}_i + b \geq 1 \\ \text{负样本} (y_i = -1): \mathbf{w}^T \mathbf{x}_i + b \leq -1 \end{array} \right\} \begin{array}{l} y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \\ i = 1, \dots, m \end{array}$$

将训练样本分开的超平面可能有很多，哪一个更好呢？



直观上应选择“正中间”，容忍性好，鲁棒性高，泛化能力最强。



支持向量与间隔

超平面方程：

$$\mathbf{w}^T \mathbf{x} + b = 0$$


$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, \dots, m$$

距离超平面最近的几个训练样本使得等式成立，它们被称为
“支持向量” (Support Vector)

两个异类支持向量
到超平面的距离之
和为

$$\gamma = \frac{2}{\|\mathbf{w}\|_2}$$

“间隔” (Margin)





SVM的基本模型

最大间隔(Large Margin):


$$\max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|_2}$$

$$\text{s.t., } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, \dots, m$$



$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2$$

$$\text{s.t., } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, \dots, m$$



“正中间”的泛化
能力最强

- 凸二次规划问题，能用优化计算包求解。
- 若 $d > m$, 使用拉格朗日乘子法效率更高



带有约束的优化问题

带有约束的优化问题

$$\begin{cases} \min_{x \in D} f(x) \\ \text{s.t. } g_i(x) \leq 0, i = 1, 2, \dots, q \\ h_j(x) = 0, j = q + 1, \dots, m \end{cases}$$

其中 $f(x)$ 是目标函数， $g(x)$ 为不等式约束， $h(x)$ 为等式约束。

若 $f(x)$, $h(x)$, $g(x)$ 三个函数都是线性函数，则该优化问题称为线性规划。
若任意一个是非线性函数，则称为非线性规划。


若目标函数为二次函数，约束全为线性函数，称为二次规划。

若 $f(x)$ 为凸函数， $g(x)$ 为凸函数， $h(x)$ 为线性函数，则该问题称为凸优化。
注意这里不等式约束 $g(x) \leq 0$ 则要求 $g(x)$ 为凸函数，若 $g(x) \geq 0$ 则要求 $g(x)$ 为凹函数。


凸优化的任一局部极值点也是全局极值点，局部最优也是全局最优。



凹凸性



凹



凸



拉格朗日乘子法

- Lagrange Multiplier Method
- 用途：消除或简化优化问题中的约束

$$\min_{\mathbf{x}} f(\mathbf{x})$$

$$\text{s.t. } g_i(\mathbf{x}) = 0, i = 1, \dots, m$$

$$h_i(\mathbf{x}) \leq 0, i = 1, \dots, n$$

拉格朗日乘子：

$$\boldsymbol{\alpha} = [\alpha_1; \dots; \alpha_m]$$

$$\boldsymbol{\beta} = [\beta_1; \dots; \beta_n], \beta_i \geq 0$$

拉格朗日函数： $L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f(\mathbf{x}) + \sum_{i=1}^m \alpha_i g_i(\mathbf{x}) + \sum_{i=1}^n \beta_i h_i(\mathbf{x})$

$$\max_{\boldsymbol{\alpha}, \boldsymbol{\beta}} \min_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$$

$$\text{s.t., } \beta_i \geq 0, i = 1, \dots, n$$



SVM的对偶问题

$$\begin{aligned} & \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{s.t., } & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, i = 1, \dots, m \end{aligned}$$

□ 第一步：引入拉格朗日乘子 $\alpha = [\alpha_1; \dots; \alpha_m]$, $\alpha_i \geq 0$, 得到拉格朗日函数：

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|_2^2 + \sum_{i=1}^m \alpha_i (1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))$$

□ 第二步：求解 $\min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha)$, 即对 \mathbf{w} 与 b 的偏导数为 0, 得：

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0 \quad -\frac{1}{2} \mathbf{w}^T \mathbf{w} + \sum_{i=1}^m \alpha_i$$

□ 第三步：回代可得对偶问题 (Dual Problem) :

$$\begin{aligned} & \min_{\alpha} \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t., } & \sum_{i=1}^m \alpha_i y_i = 0; \alpha_i \geq 0, i = 1, \dots, m \end{aligned}$$

b 怎么求？



解的稀疏性

最终预测模型: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^m \underbrace{\alpha_i y_i \mathbf{x}_i^T \mathbf{x}}_{\text{支持向量}} + b$

训练完成后，预测模型只和支持向量有关

□ Karush-Kuhn-Tucker (KKT) 条件:

$$\begin{cases} \alpha_i \geq 0 \\ y_i f(\mathbf{x}_i) - 1 \geq 0 \\ \alpha_i(y_i f(\mathbf{x}_i) - 1) = 0 \end{cases} \rightarrow \begin{array}{l} \text{必有 } \alpha_i = 0 \\ \text{或 } y_i f(\mathbf{x}_i) = 1 \end{array}$$

支持向量

参数 b 的求法:

设 \mathbf{x}_j 为支持向量, 即 $y_j (\mathbf{w}^T \mathbf{x}_j + b) = 1$

$$b = \frac{1}{y_j} - \mathbf{w}^T \mathbf{x}_j = y_j - \mathbf{w}^T \mathbf{x}_j$$


$$b^* = \frac{1}{|\text{SV}|} \sum_{\mathbf{x}_j \in \text{SV}} (y_j - \mathbf{w}^T \mathbf{x}_j)$$



特征空间映射

□ 若不存在一个能正确划分两类样本的超平面, 怎么办?

将样本从原始空间映射到一个更高维的特征空间, 使样本在这个特征空间内线性可分



如果原始空间是有限维（属性数有限），那么一定存在一个高维特征空间使样本线性可分



在特征空间中

□ 预测模型：

$$f(\mathbf{x}) = \mathbf{w}^T \phi(\mathbf{x}) + b$$

□ 原始问题：

$$\min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w}\|_2^2$$

$$\text{s.t. } y_i(\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1, i = 1, \dots, m$$

□ 对偶问题：

$$\min_{\alpha} \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j \boxed{\phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)} - \sum_{i=1}^m \alpha_i$$

$$\text{s.t., } \sum_{i=1}^m \alpha_i y_i = 0; \alpha_i \geq 0, i = 1, \dots, m$$

□ 最终预测模型：

$$f(\mathbf{x}) = \sum_{i=1}^m \alpha_i y_i \boxed{\phi(\mathbf{x}_i)^T \phi(\mathbf{x})} + b$$

只以内积形式出现！



核函数

□ 核函数(kernel function): 衡量样本在特征空间中的相似度

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) \quad \text{绕过得到显式特征映射的困难}$$

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ _2^2}{2\sigma^2}\right)$	$\sigma > 0$ 为高斯核的带宽
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ _2}{\sigma}\right)$	$\sigma > 0$ 为拉普拉斯核的带宽

□ 核函数选择成为决定SVM性能的关键！情况不明时：

- 若 $d \geq m$, 选用线性核
- 若 $d < m$, 选用高斯核

□ 可对核函数进行学习，核学习(Kernel Learning)


- 难度和学习特征映射 ϕ 差不多



软间隔

- 现实中很难找到合适的核函数，使训练样本在特征空间中线性可分
- 即便线性可分，也很难断定是否会导致过拟合

引入**软间隔**(soft margin)，允许在一些样本上不满足约束





软间隔SVM

引入松弛变量:

$$\begin{aligned} & \min_{\mathbf{w}, \xi} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t., } & y_i (\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i, \xi_i \geq 0 \end{aligned}$$

对偶问题:


$$\begin{aligned} & \min_{\alpha} \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t., } & \sum_{i=1}^m \alpha_i y_i = 0; 0 \leq \alpha_i \leq C, i = 1, \dots, m \end{aligned}$$



多分类

拆解法：将一个多分类任务拆分为若干个二分类任务求解

- 训练N(N-1)/2个分类器，存储开销和测试时间大
- 训练只用两个类的样例，训练时间短





Take Home Message

- 支持向量机的“最大间隔”思想
- 对偶问题及其解的稀疏性
- 通过向高维空间映射解决线性不可分的问题
- 引入“软间隔”缓解特征空间中线性不可分的问题