



# 人工智能 I

杨杰

[yangjie@seu.edu.cn](mailto:yangjie@seu.edu.cn)

2025/11/24, 五四楼-303, 9:50~11:25



# 本周四实验课安排

周次	10	
日期	2025/11/27	
星期	星期四	
时间	16:40-18:15	19:00-20:35
机房地点	中心楼实验室 D区	五五楼435 软实七
实验任务	决策树与随机森林	

注意两个时间段是不同机房！请勿跑错！  
注意18:15机房电脑自动关机！请及时保存！



# 本节课安排

## □ 监督学习：

- 线性回归
- 对率回归
- 支持向量机
- 决策树
- 随机森林
- 贝叶斯分类器
- 感知机与神经网络





# 本节课安排

## □ 监督学习：

- 线性回归
- 对率回归
- 支持向量机
- **决策树 Decision Tree**
- 随机森林
- 贝叶斯分类器
- 感知机与神经网络





# 决策树 (Decision Tree)

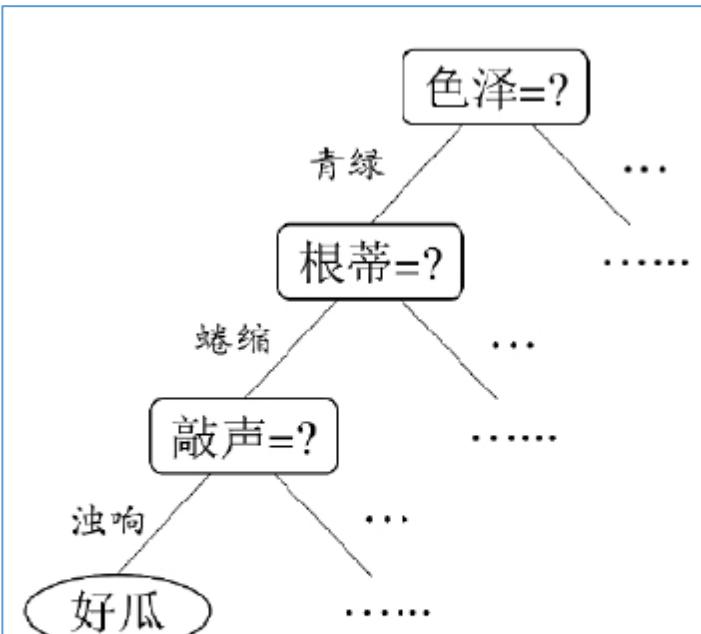


图 4.1 西瓜问题的一棵决策树

表 1.1 西瓜数据集

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	浊响	否
3	青绿	硬挺	清脆	否
4	乌黑	稍蜷	沉闷	否

决策树基于树结构进行决策（与人的决策过程类似）：

- 每个“内部节点”对应于某个属性上的测试
- 每个分支对应于该测试的一种可能结果（即该属性的某个取值）
- 每个“叶节点”对应于一个预测结果

学习过程：寻找一颗能（尽量）正确划分训练集的决策树，寻求最优泛化性能

预测过程：将测试样本从根节点开始，沿着划分属性所构成的“判定测试序列”下行，直到叶节点



# 基本思路

在每个中间节点寻找一个“最优”划分属性，试图用一颗“尽量小”的决策树获得“尽量低”的训练误差

基本流程：分而治之，自根至叶的递归过程

TreeGenerate( $D, A$ )      数据集 $D$ , 属性集 $A$

- 选择划分属性 $a$ （含 $V$ 个属性值），把 $D$ 划分为 $D^1 \cup D^2 \cup \dots \cup D^V$ ,  $D^v = \{\mathbf{x} | \mathbf{x} \in D, x_a = a^v\}$
- TreeGenerate( $D^v, A \setminus \{a\}$ ),  $v = 1, \dots, V$

三种停止条件：

- (1) 当前节点包含的样本全属于同一类别，无需划分；
- (2) 当前属性集为空，或是所有样本在所有属性上取值相同，无法划分；
- (3) 当前节点包含的样本集合为空，不能划分。



# 基本算法

输入: 训练集  $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ;  
属性集  $A = \{a_1, a_2, \dots, a_d\}$ .

过程: 函数 TreeGenerate( $D, A$ )

1: 生成结点 node;

2: if  $D$  中样本全属于同一类别  $C$  then

3: 将 node 标记为  $C$  类叶结点; return

4: end if

5: if  $A = \emptyset$  OR  $D$  中样本在  $A$  上取值相同 then

6: 将 node 标记为叶结点, 其类别标记为  $D$  中样本数最多的类; return

7: end if

8: 从  $A$  中选择最优划分属性  $a_*$ ;

9: for  $a_*$  的每一个值  $a_*^v$  do

10: 为 node 生成一个分支; 令  $D_v$  表示  $D$  中在  $a_*$  上取值为  $a_*^v$  的样本子集;

11: if  $D_v$  为空 then

12: 将分支结点标记为叶结点, 其类别标记为  $D$  中样本最多的类; return

13: else

14: 以 TreeGenerate( $D_v, A \setminus \{a_*\}$ ) 为分支结点

15: end if

16: end for

输出: 以 node 为根结点的一棵决策树

递归返回,  
情形(1)

递归返回,  
情形(2)

当前结点的类后验分布

递归返回,  
情形(3)

采用父结点的类  
后验分布

决策树算法的  
核心



# 信息熵

- 信息熵 (entropy) 描述的是随机变量的信息量（不确定性），是度量样本集合**纯度**最常用的一种指标
  - 大多数样本属于同一类，则纯度高；反之，纯度低
- 假定当前样本集合 $D$ 中第 $k$ 类样本所占的比例为 $p_k, k = 1, \dots, N$ ，我们把 $D$ 的信息熵定义为：

$$H(D) = - \sum_{k=1}^N p_k \log_2 p_k$$

- 约定 $0 \log_2 0 = 0$
- $0 \leq H(D) \leq \log_2 N$
- **$H(D)$ 越小，纯度越高**



# 熵 (Entropy)

- 熵(Entropy): 随机变量  $X$  的概率分布为  $P$ ，其信息量（不确定量）为：

$$H(X) = \mathbf{E}[I(x)] = -\mathbf{E}[\log P(x)] = -\sum P(x) \log P(x)$$

- 也记为  $H(P)$ ，描述概率分布的性质
- 熵是信息中不确定性的平均度量
- **不确定性越高，熵越大**
- 例如，抛一枚均匀的硬币，结果（正面或反面）的熵很高，因为你完全无法预测。



# 一个例子

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

17个样本

$$\text{正例占 } p_1 = \frac{8}{17}$$

$$\text{反例占 } p_2 = \frac{9}{17}$$

划分前的信息熵：

$$H(D) = -p_1 \log_2 p_1 - p_2 \log_2 p_2 = 0.998$$



# 一个例子

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

若以色泽为划分属性：

- $D^1$  (色泽=青绿), 6个样  
本正例占 $\frac{3}{6}$ , 反例占 $\frac{3}{6}$ ,  
其信息熵为:

$$H(D^1) = 1$$

- $D^2$  (色泽=乌黑) 与  
 $D^3$  (色泽=浅白) 的信息  
熵为:

$$H(D^2) = 0.918$$
$$H(D^3) = 0.722$$

$$\text{Ent}(D^1) = -\left(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6}\right) = 1.000$$

$$\text{Ent}(D^2) = -\left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}\right) = 0.918$$

$$\text{Ent}(D^3) = -\left(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5}\right) = 0.722$$



# 信息增益

- 信息增益 (information gain) 以信息熵为基础，计算某个划分对信息熵所造成的变化
    - 设属性 $a$ 的值域为 $\{a^1, a^2, \dots, a^V\}$
    - $D^v$ : 数据集 $D$ 中在属性 $a$ 上取值为 $a^v$ 的样本集合
    - 以属性 $a$ 对数据集 $D$ 进行划分，所取得的信息增益为

$$\text{Gain}(D, a) = H(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} H(D^v)$$

↓

划分前的信息熵

↓

划分后的信息熵

↓

第 $v$ 个分支的权重, 样本越多权重越高



# 一个例子

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

属性“色泽”的信息增益为：

$$\text{Gain}(D, \text{色泽}) = H(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} H(D^v) = 0.109$$

若以色泽为划分属性：

- $D^1$  (色泽=青绿), 6个样本正例占  $\frac{3}{6}$ , 反例占  $\frac{3}{6}$ , 其信息熵为：  
 $H(D^1) = 1$
- 同理,  $D^2$  (色泽=乌黑) 与  $D^3$  (色泽=浅白) 的信息熵为：  
 $H(D^2) = 0.918$   
 $H(D^3) = 0.722$

划分后的信息熵：

$$\sum_{v=1}^3 \frac{|D^v|}{|D|} H(D^v) = 0.889$$



# 一个例子

$$\text{Ent}(D^1) = -\left(\frac{3}{6} \log_2 \frac{3}{6} + \frac{3}{6} \log_2 \frac{3}{6}\right) = 1.000$$

$$\text{Ent}(D^2) = -\left(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}\right) = 0.918$$

$$\text{Ent}(D^3) = -\left(\frac{1}{5} \log_2 \frac{1}{5} + \frac{4}{5} \log_2 \frac{4}{5}\right) = 0.722$$

$$\begin{aligned}\text{Gain}(D, \text{色泽}) &= \text{Ent}(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722\right) \\ &= 0.109\end{aligned}$$



# 课堂练习

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

练习：计算

$\text{Gain}(D, \text{根蒂})$

$\text{Gain}(D, \text{敲声})$

$\text{Gain}(D, \text{纹理})$

$\text{Gain}(D, \text{脐部})$

$\text{Gain}(D, \text{触感})$



# 一个例子

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

$$\text{Gain}(D, \text{ 色泽}) = 0.109$$

$$\text{Gain}(D, \text{ 根蒂}) = 0.143$$

$$\text{Gain}(D, \text{ 敲声}) = 0.141$$

$$\text{Gain}(D, \text{ 纹理}) = 0.381$$

$$\text{Gain}(D, \text{ 脐部}) = 0.289$$

$$\text{Gain}(D, \text{ 触感}) = 0.006$$

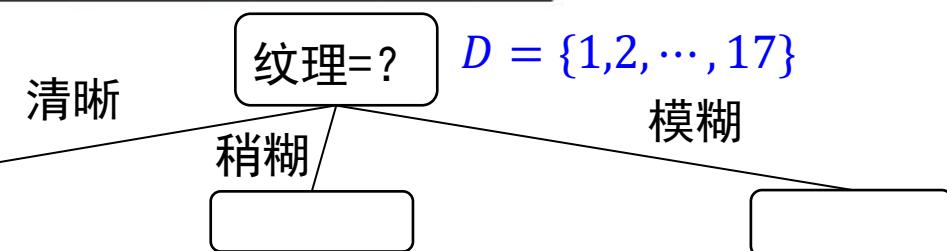


# 一个例子

表 4.1 西瓜数据集 2.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

$\text{Gain}(D, \text{ 色泽}) = 0.109$   
 $\text{Gain}(D, \text{ 根蒂}) = 0.143$   
 $\text{Gain}(D, \text{ 敲声}) = 0.141$   
 $\text{Gain}(D, \text{ 纹理}) = 0.381$   
 $\text{Gain}(D, \text{ 脐部}) = 0.289$   
 $\text{Gain}(D, \text{ 触感}) = 0.006$



$$D^1 = \{1,2,3,4,5,6,8,10,15\}$$

$$D^2 = \{7,9,13,14,17\}$$

$$D^3 = \{11,12,16\}$$



# 选择划分属性准则

- 信息增益越大意味着用该属性来划分所获得的“纯度提升”越大
- 因此可以用信息增益来进行决策树的划分属性选择

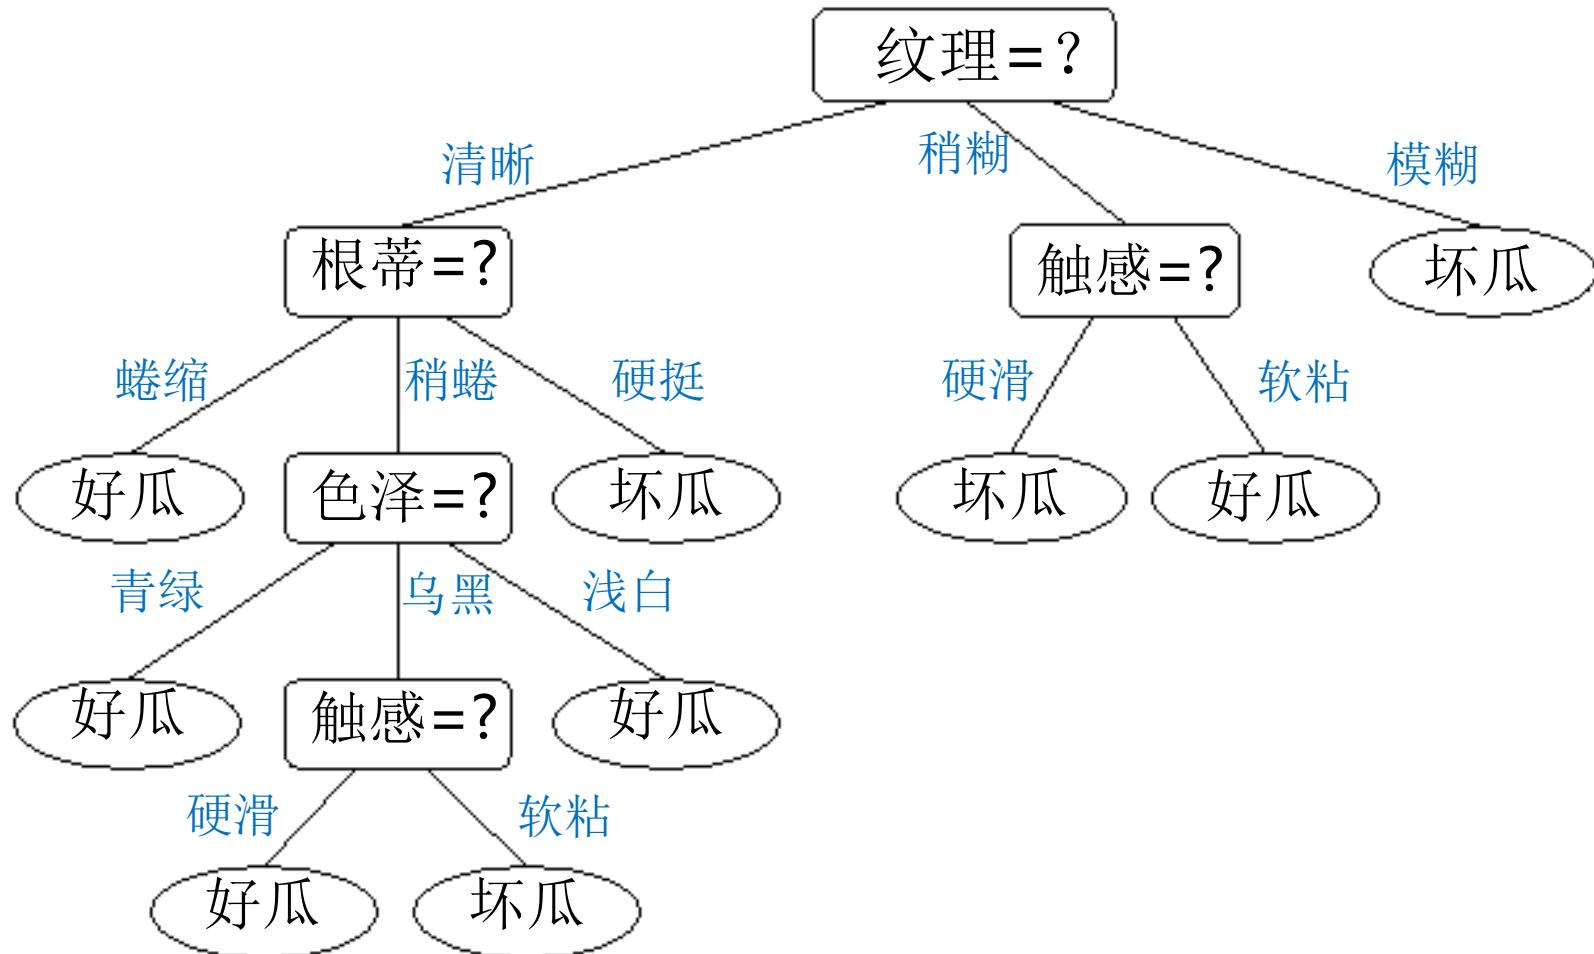
$$\text{Gain}(D, a) = H(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} H(D^v)$$

- 著名的ID3决策树学习算法就是以信息增益为准则来选择划分属性



# 决策树

对每个分支结点做进一步划分，最终得到决策树





# 一个例子

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

D<sup>1</sup>



# 增益率

- 信息增益的缺点：偏向于选择取值多的属性
  - 可能导致过拟合，比如把“编号”当做一个属性
- 增益率(gain ratio)

$$\text{Gain\_Ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)}$$

- $\text{IV}(a)$ 表示属性 $a$ 的固有值(intrinsic value)

$$\text{IV}(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \left( \frac{|D^v|}{|D|} \right)$$

- 问题彻底解决了?  
NO! 增益率偏向于选择取值少的属性

启发式：先从候选划分属性中找出信息增益高于平均水平的，再从中选取增益率最高的



# 关于决策树

- 解决多分类问题的通用方法
  - 适用于属性值离散的数据
  - 也适用于属性值连续的数据（需对数据进行离散化）
  - 特点：**对划分属性的选择很敏感！**
- 优点：学习能力强（拟合能力强）、可应对缺失值
- 缺点：容易导致过拟合
  - 剪枝
    - ✓ 预剪枝
    - ✓ 后剪枝
- 一种强大的改进：随机森林
  - 下一小节……



# 本节课安排

## □ 监督学习：

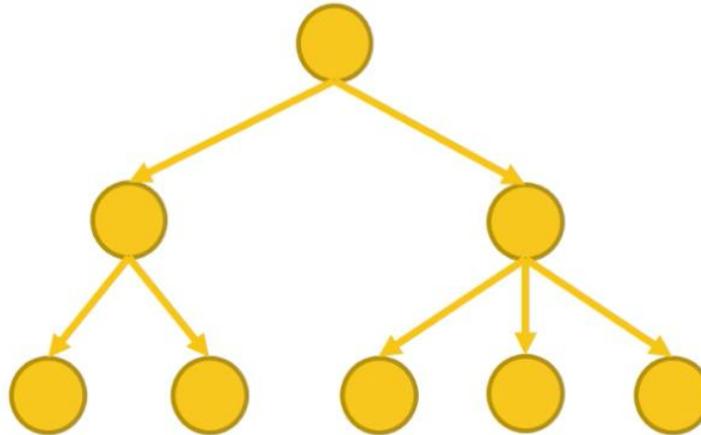
- 线性回归
- 对率回归
- 支持向量机
- 决策树
- 随机森林
- 贝叶斯分类器
- 感知机与神经网络



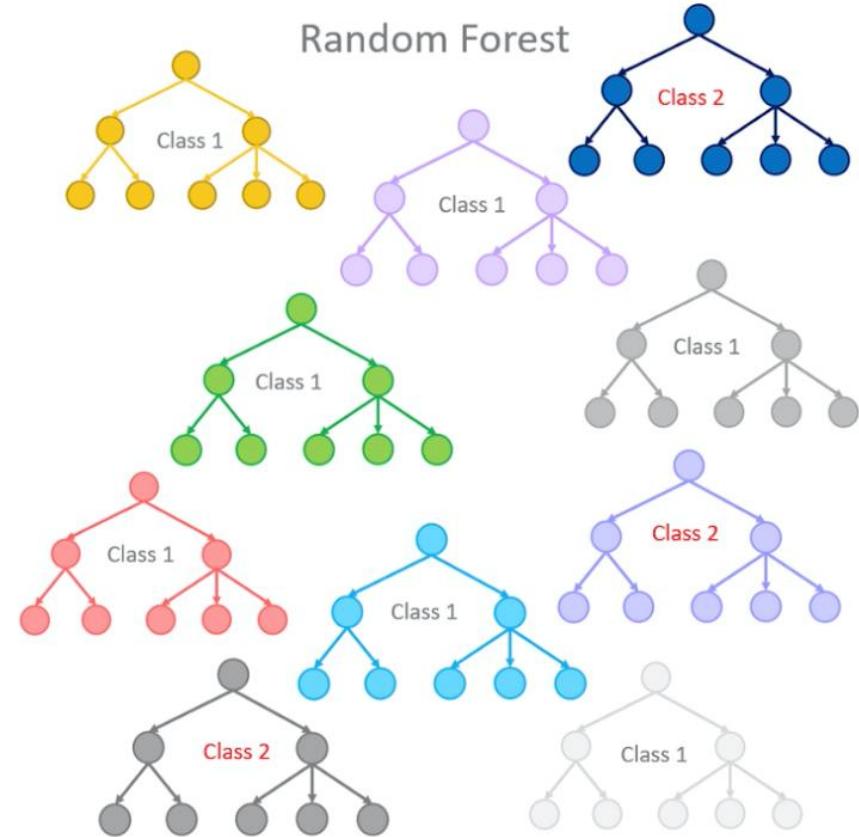


# 随机森林

Single Decision Tree



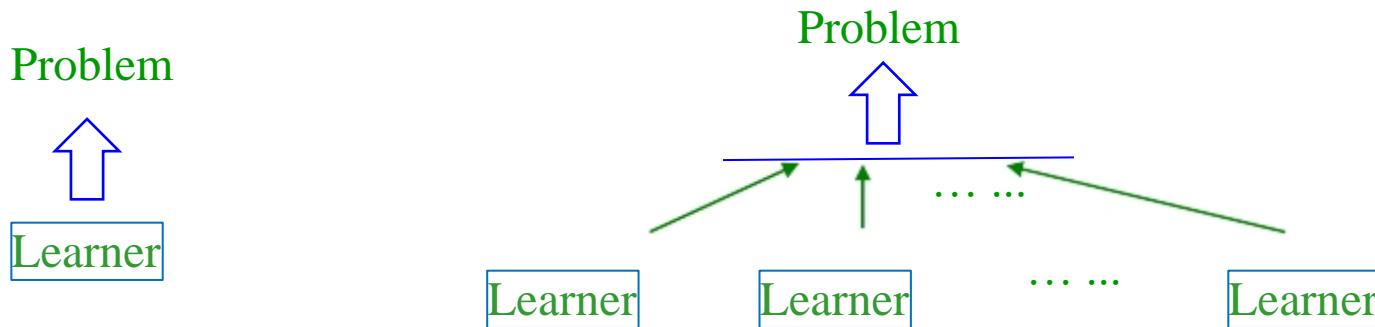
Random Forest





# 集成学习

集成学习(Ensemble Learning): 通过构建并结合多个学习器来完成学习任务



- 同质(homogeneous)集成: 集成中只包含同种类型的“个体学习器”， 相应的学习算法称为“基学习算法” (base learning algorithm), 个体学习器亦称“基学习器” (base learner)
- 异质(heterogeneous)集成: 个体学习器由不同的学习算法生成，一般不叫“基学习算法”



# 常用结合方法

## ➤ 分类问题

- $h_i$  表示第  $i$  个基学习器,  $i = 1, \dots, T$
- $h_i^j$  表示  $h_i$  在类别标记  $c_j$  上的预测输出,  $j = 1, \dots, N$ 
  - $h_i^j(\mathbf{x})$  表示  $h_i$  预测  $\mathbf{x}$  属于  $c_j$  的概率 (或评分)
- **投票法:**
  - 绝对多数投票法

$$H(\mathbf{x}) = \begin{cases} c_j, & \text{if } \sum_{i=1}^T h_i^j(\mathbf{x}) > 0.5 \\ \text{reject}, & \text{else.} \end{cases}$$

T

$\sum_{k=1}^N \sum_{i=1}^T h_i^k(\mathbf{x})$

- 相对多数投票法

$$H(\mathbf{x}) = c_{j^*}, j^* = \arg \max_j \sum_{i=1}^T h_i^j(\mathbf{x})$$

- 加权投票法

$$H(\mathbf{x}) = c_{j^*}, j^* = \arg \max_j \sum_{i=1}^T w_i h_i^j(\mathbf{x})$$

## ➤ 回归问题

- 简单平均法
- 加权平均法



# 如何得到好的集成?

令个体学习器好而不同!

	测试例1	测试例2	测试例3
$h_1$	✓	✓	✗
$h_2$	✗	✓	✓
$h_3$	✓	✗	✓
集成	✓	✓	✓

(a) 集成提升性能

	测试例1	测试例2	测试例3
$h_1$	✓	✓	✗
$h_2$	✓	✓	✗
$h_3$	✓	✓	✗
集成	✓	✓	✗

(b) 集成不起作用

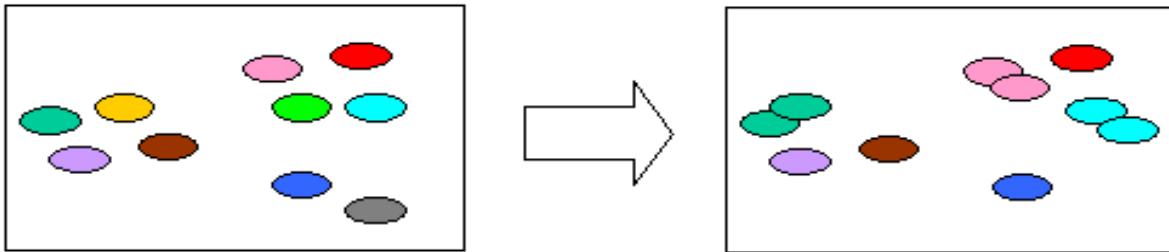
	测试例1	测试例2	测试例3
$h_1$	✓	✗	✗
$h_2$	✗	✓	✗
$h_3$	✗	✗	✓
集成	✗	✗	✗

(c) 集成起负作用



# Bagging

- Bagging: 基于一种学习算法、一个数据集的集成方法
  - 有回放采样(bootstrap sampling), 也称可重复采样



- ✓ 生成和原数据集一样大的新数据集
- ✓ 约有36.8% 的样本不出现

- 算法框架: 通过数据扰动, 获得具有一定差异性的基学习器

训练阶段: 训练集  $D = \{(x_i, y_i)\}_{i=1}^m$ ; 基学习算法  $\mathcal{L}$ ;  
训练轮数目  $T$

For  $t = 1, \dots, T$

对  $D$  进行有回放采样, 得到  $D_t$ ;

$h_t = \mathcal{L}(D_t)$ ;

End For

测试阶段 (分类) : 相对多数投票法

• 决策树



# 随机森林

---

- 随机森林(Random Forest, 简称RF)是bagging的一个扩展变种
- 采样的随机性
- 属性选择的随机性



# 随机森林

## □ 随机森林(Random Forest)

- 采样Bagging算法框架，基学习器为决策树
- 增加基学习器的差异性：

➤ 设当前节点的属性集合为 $A = \{a_1, \dots, a_d\}$ 。从 $A$ 中随机选取包含 $k$ 个属性的子集，记为 $A'$

- $k = \log_2 d$

➤ 从 $A'$ 中选择最优划分属性：

- 推荐：先从候选划分属性中找出信息增益高于平均水平的，再从中选取增益率最高的

## □ 随机森林被誉为代表集成学习技术水平的方法



# 练习

小张喜欢吃西瓜，但时不时会买到不好吃的坏瓜。经过《人工智能导论》的学习后，小张决定使用机器学习方法改善自己买西瓜的策略。小张收集了 8 个西瓜数据样本：

编号	色泽青绿	根蒂蜷缩	敲声浊响	好瓜？
1	1	1	1	1
2	0	1	0	1
3	0	1	1	1
4	1	1	0	1
5	0	0	0	-1
6	1	0	0	-1
7	0	0	1	-1
8	1	0	1	-1

如果使用决策树对以上数据进行判别训练，请计算把每个属性作为划分属性的信息增益(Information Gain)。