

# 从体征到判别：心脏病数据的聚类、因子分析与预测模型对比

## 课程设计成果汇报

08023110陈奕诚, 08023214张韫译萱, 08023203周一鸣

2025.12.30

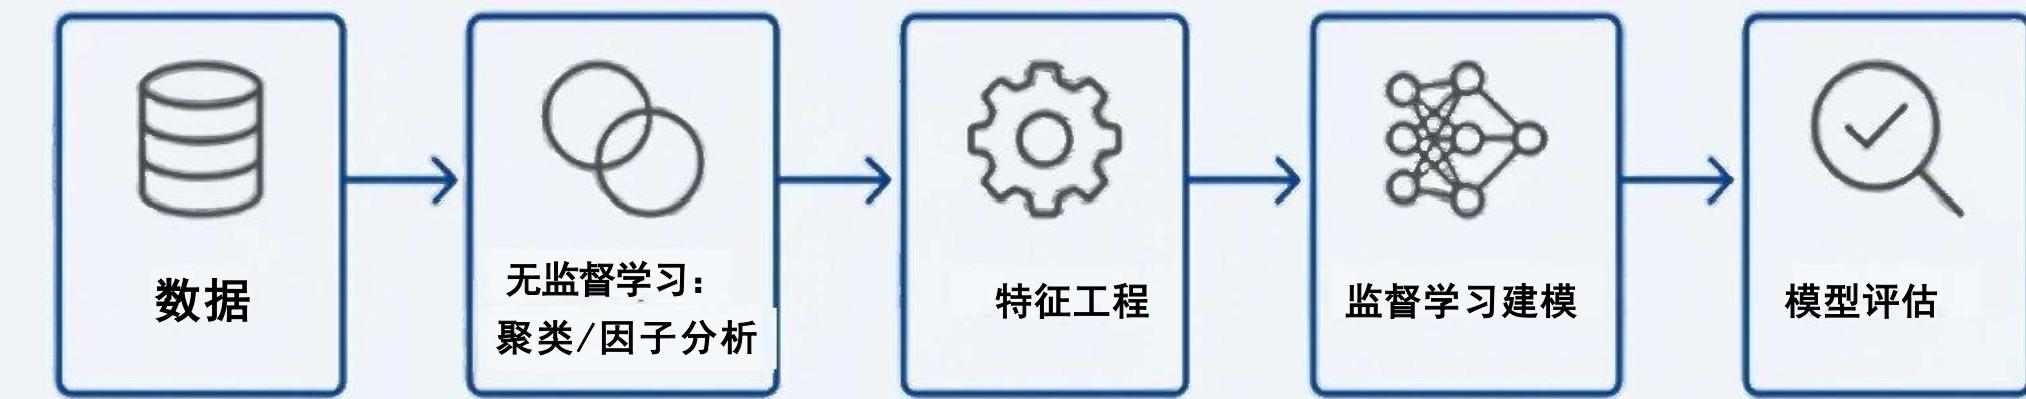
# 01/项目背景与分析思路

## 核心问题：

心脏病是全球主要健康威胁，早期筛查与精准预测至关重要。

## 数据驱动方法：

利用患者体征及检查指标，可通过数据分析构建有效的预测模型。



## 本项目分析思路：

本项目旨在探索一条完整的分析思路：从未经标记的数据中发掘结构(聚类、因子分析)，到利用这些结构构建并对比多种预测模型(Logistic 回归、贝叶斯判别)。

## 02 / 数据集与核心变量

**目标变量 (Target Variable) :**  
心脏病二分类结果 (1=有, 0=无)。

**特征类型 (Feature Types) :** 数据集包含连续型与离散型两类特征。

**初期焦点 (Initial Focus for Tasks)**

1&2)：为进行聚类与因子分析，我们首先选取5个关键连续变量进行结构探索：

- (1) age: 年龄
- (2) trestbps: 静息血压
- (3) chol: 血清胆固醇
- (4) thalach: 最大心率
- (5) oldpeak: 运动后ST段压低

年龄	性别	胸痛类型	静息血压	血清胆固醇	静息心电图结果	最大心率	运动诱发心绞痛	运动后ST段低压程度	ST段斜率类型	心脏病
70	1	4	130	322	2	109	0	2.4	2	1
57	1	2	124	261	0	141	0	0.3	1	1
64	1	4	128	263	0	105	1	0.2	2	0
74	0	2	120	269	2	121	1	0.2	1	0
65	1	4	120	177	0	140	0	0.4	1	0
56	1	3	130	256	2	142	1	0.6	2	1
59	1	4	110	239	2	142	1	1.2	2	1
60	1	4	140	293	2	170	0	1.2	2	1
63	0	4	150	407	2	154	0	4	2	1
59	1	4	135	234	0	161	0	0.5	2	0
53	1	4	142	226	2	111	1	0	1	0

## 03 / 数据预处理：Z-Score 标准化

### 挑战 (The Challenge) :

5个连续变量的量纲和取值范围差异巨大，直接分析会使距离计算和相关性分析被个别指标主导。

年龄	静息血压	血清胆固醇	最大心率	运动后ST段低压程度	心脏病
70	130	322	109	2.4	1
57	124	261	141	0.3	1
64	128	263	105	0.2	0
74	120	269	121	0.2	0
65	120	177	140	0.4	0
56	130	256	142	0.6	1
59	110	239	142	1.2	1



年龄	静息血压	血清胆固醇	最大心率	运动后ST段低压程度	心脏病
1.739810 686	- 911	0.049724 97	1.6230973 407	1.743495 407	1.171516439 1
0.302919 033	- 841	0.393278 99	0.2783754 601	0.366685 601	-0.655931433 1
1.076629 923	- 888	0.164242 42	0.3224647 633	1.915596 633	-0.74295276 0
2.181931 195	- 795	0.622314 69	0.4547324 73	1.227191 73	-0.74295276 0
1.187160 05	- 795	0.622314 87	1.5733726 907	0.409710 907	-0.568910106 0
0.192388 906	- 911	0.049724 93	0.1681523 294	0.323660 294	-0.394867451 1
0.523979 287	- 678	- 68	1.194904 294	0.2066061 294	0.323660 294
				0.127260512	1

### 解决方案 (The Solution) :

采用Z-score标准化，消除量纲影响，使各变量具有可比性。

公式：

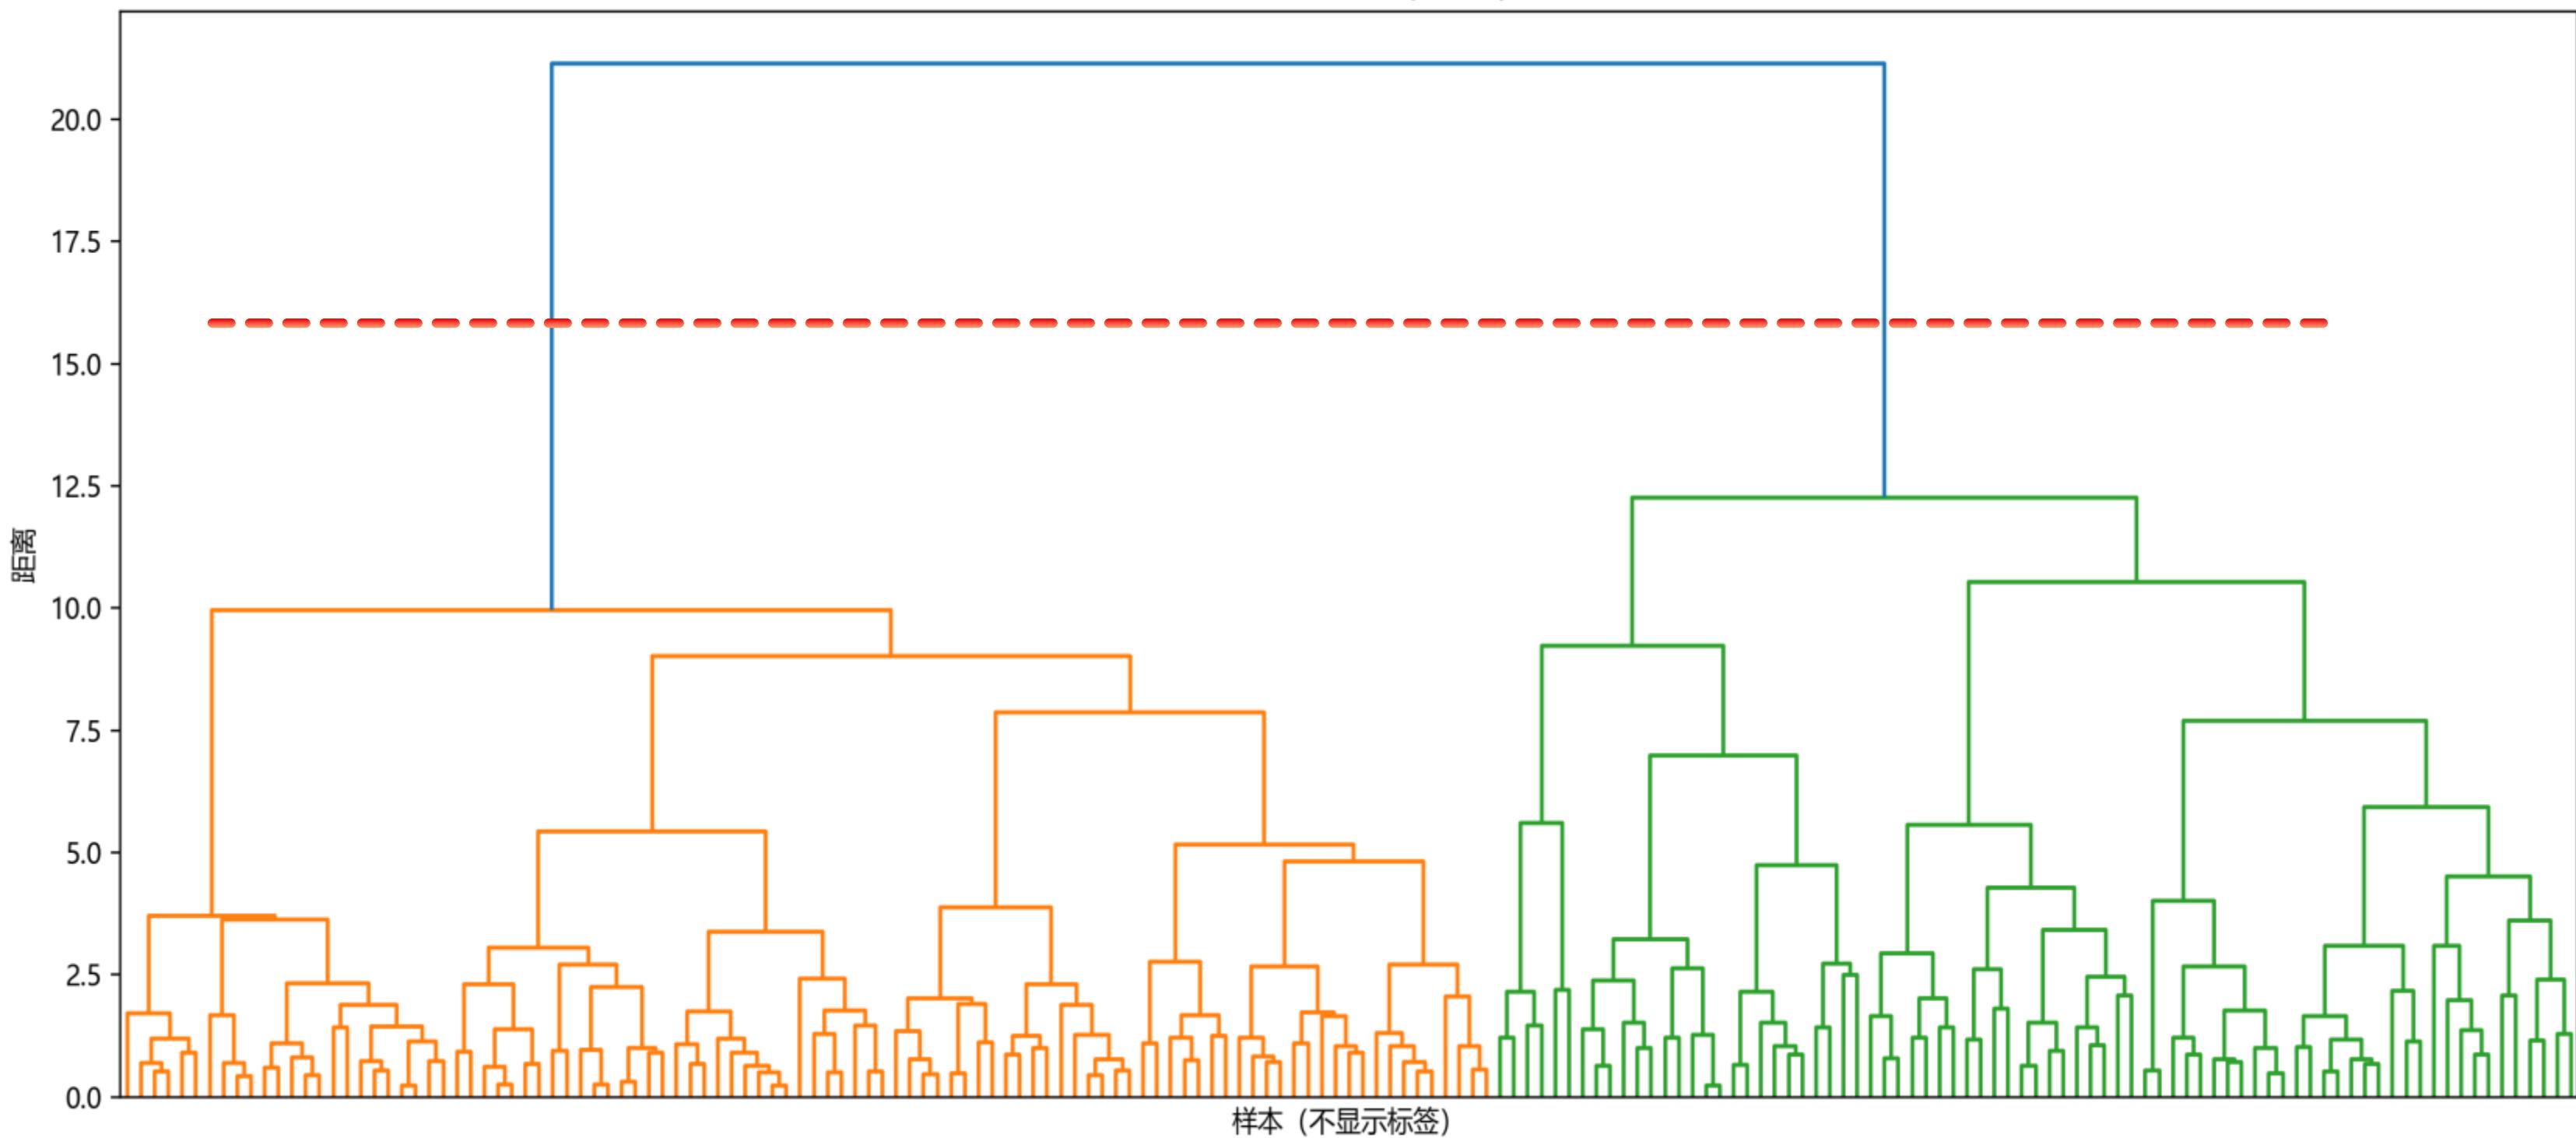
$$Z = \frac{X - \mu}{\sigma}$$

## 04/探索(一): 层次聚类揭示潜在分组

方法:

采用Ward 法进行层次聚类，该方法旨在最小化合并后的类内方差。从树状图中可见，在较高的距离水平上存在一次明显的合并“跃迁”，表明数据自然地倾向于被划分为两类。

层次聚类树状图 (Ward)



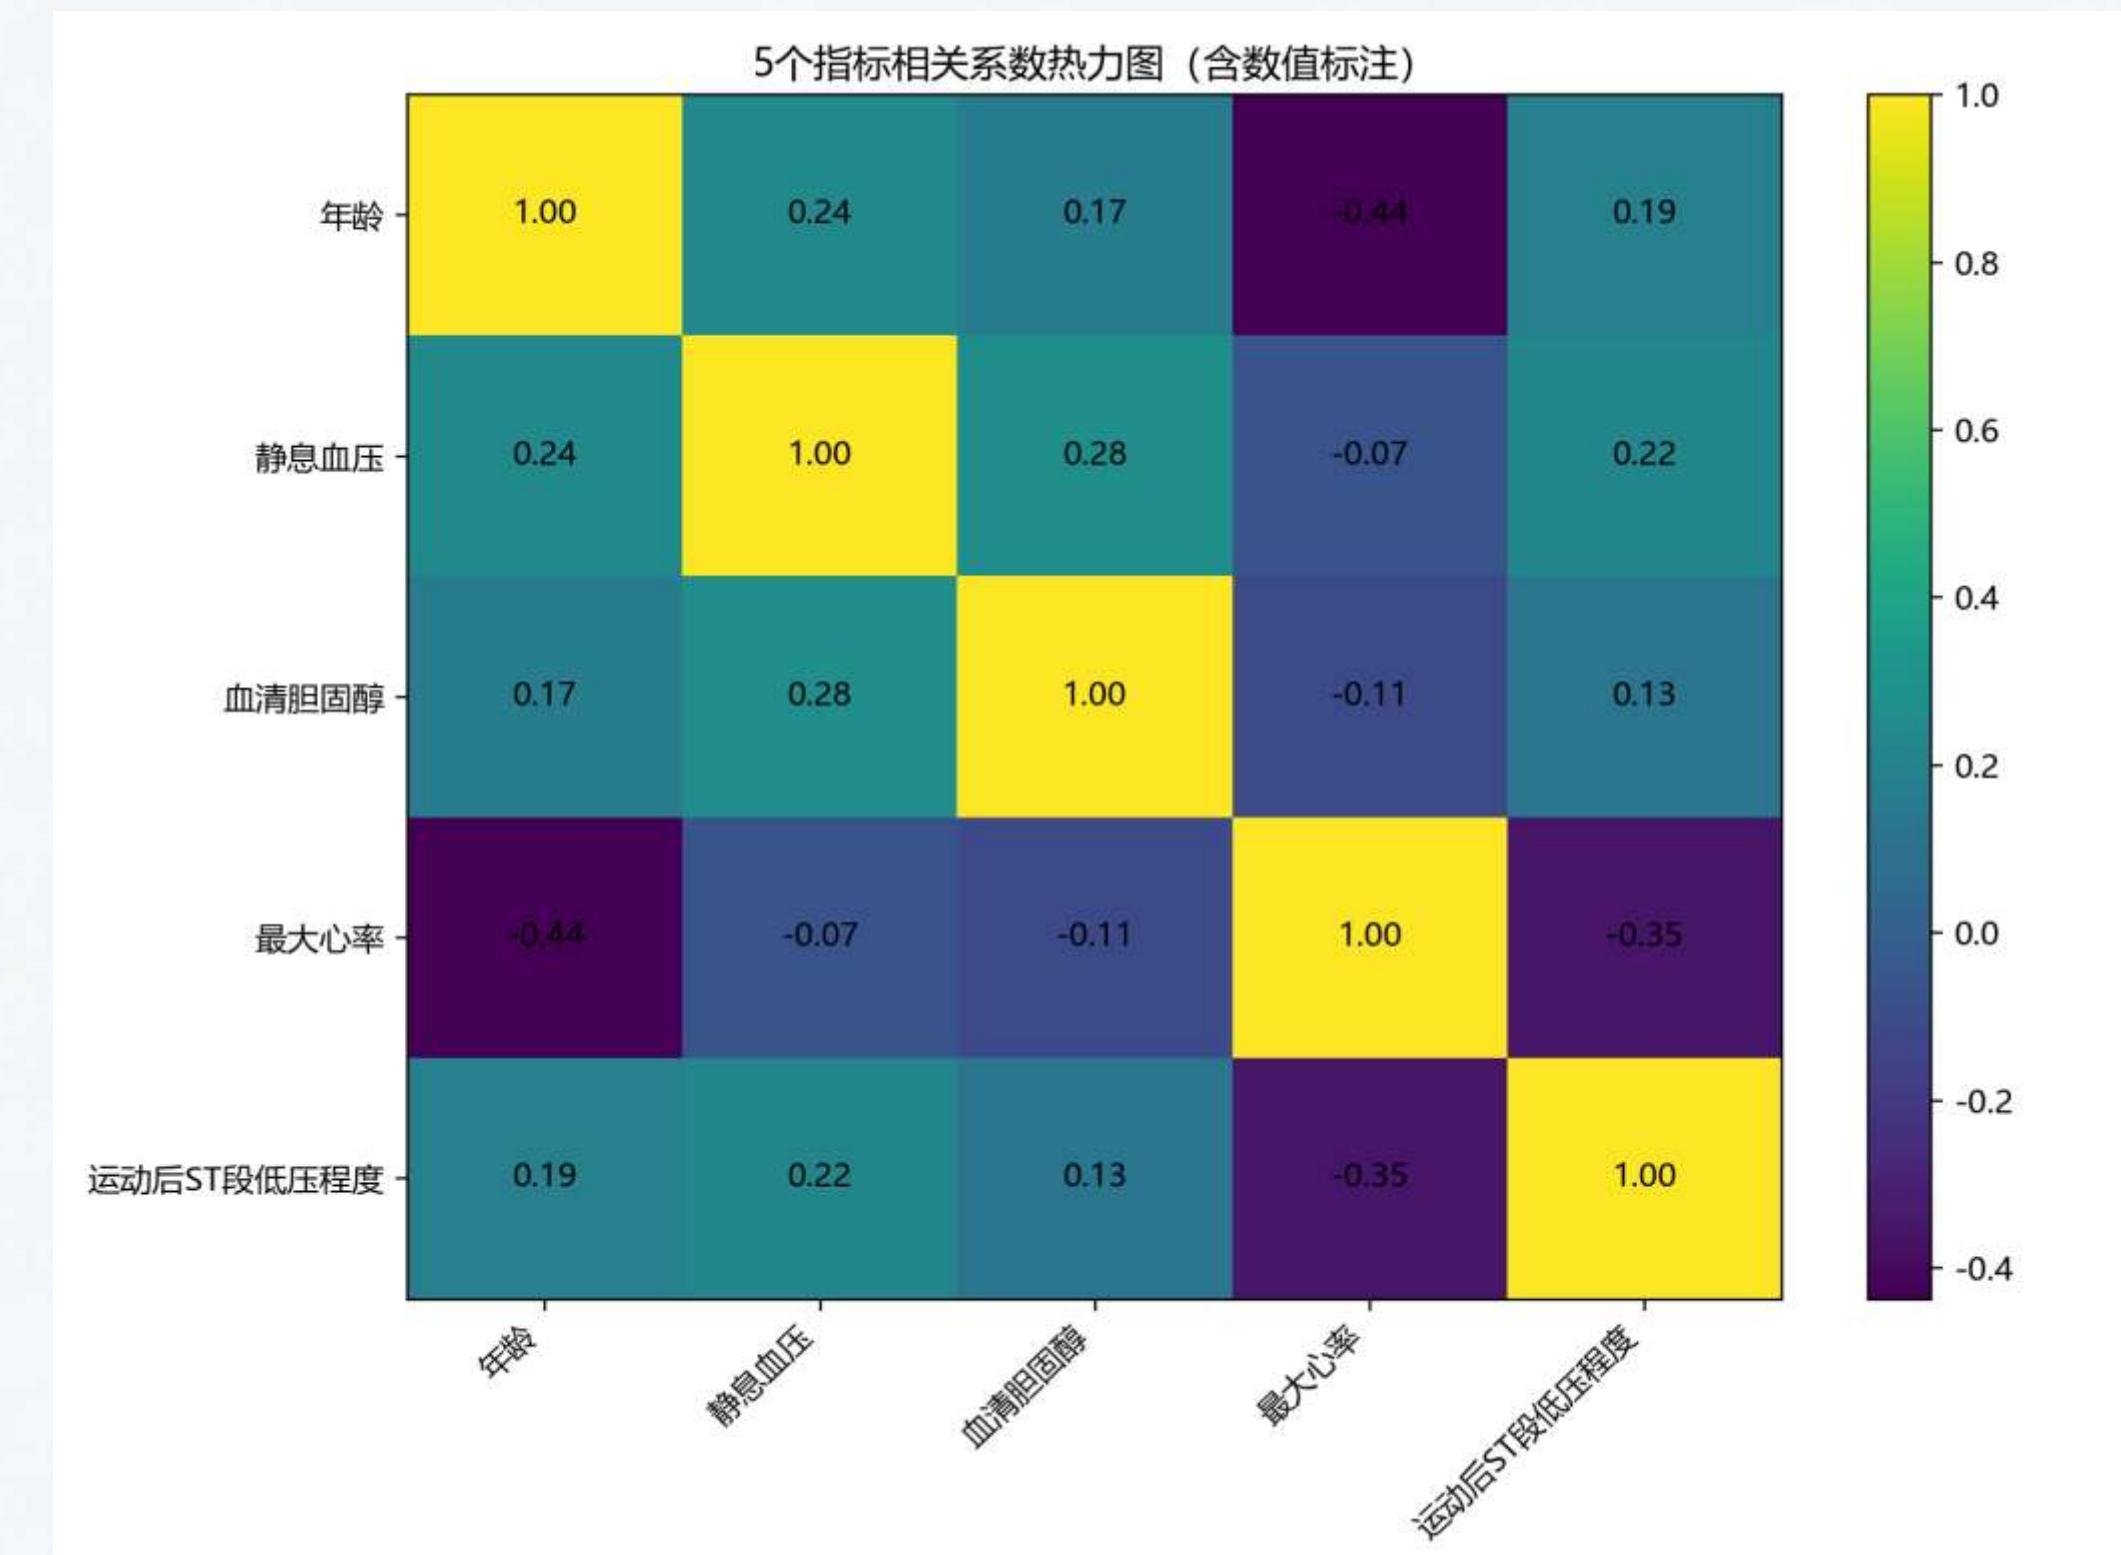
## 05/探索(二)：相关性分析寻找变量间联系

### 目标：

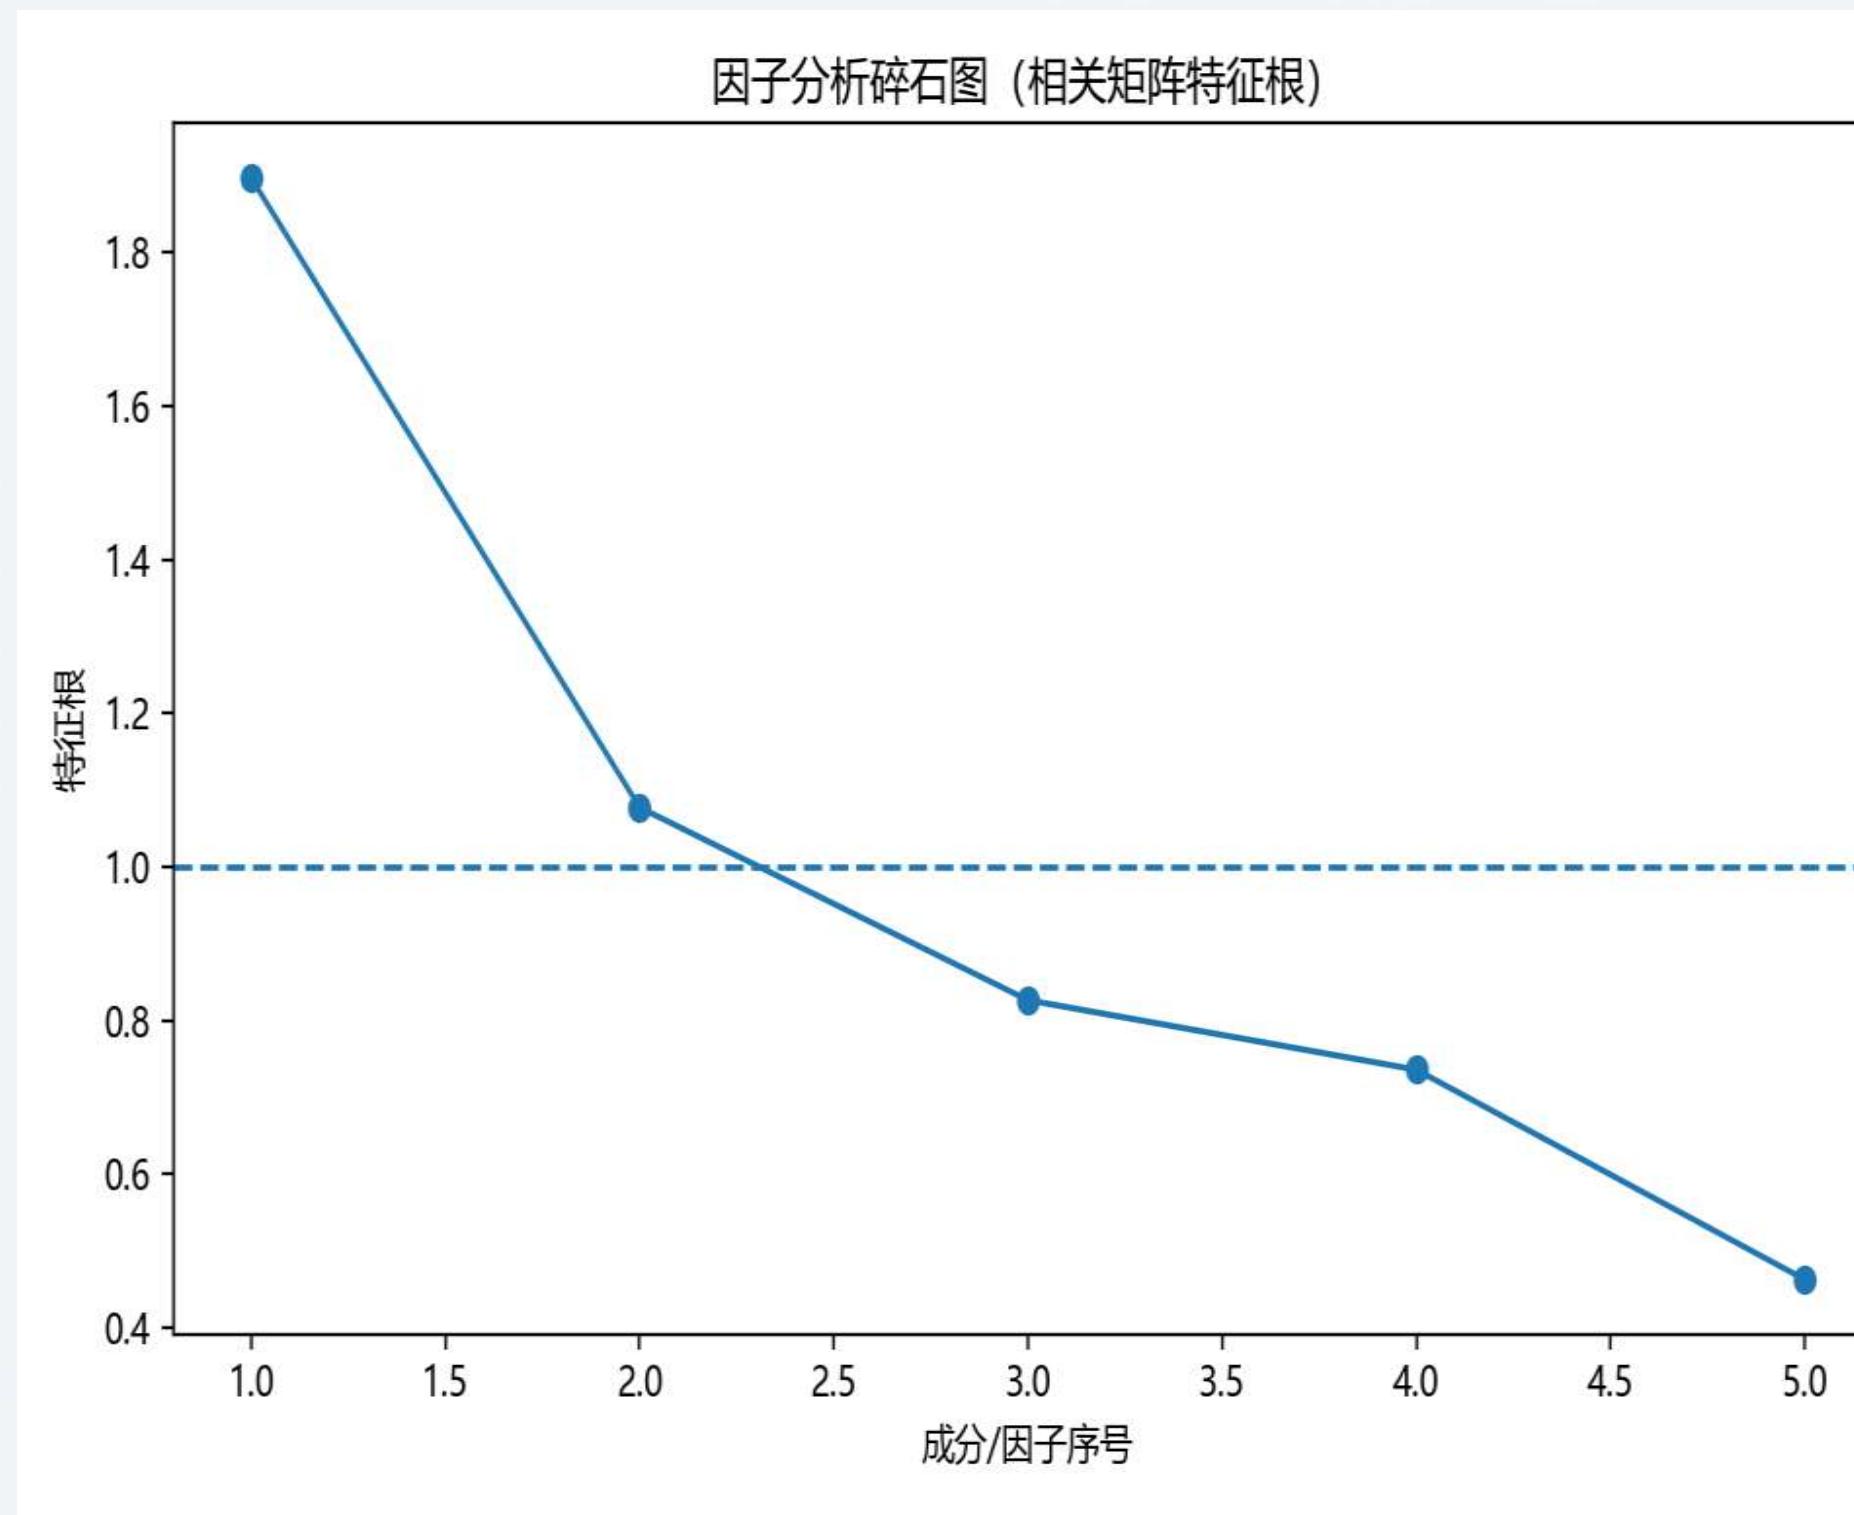
在因子分析前，检验5个变量间的相关性结构，为降维提供依据。

### 主要观察：

- (1) “年龄”与“最大心率”呈显著负相关。
- (2) “最大心率”与“运动后ST段压低”呈负相关。
- (3) “静息血压”与“血清胆固醇”存在一定正相关。



## 06 / 探索(三): 因子分析确定核心维度

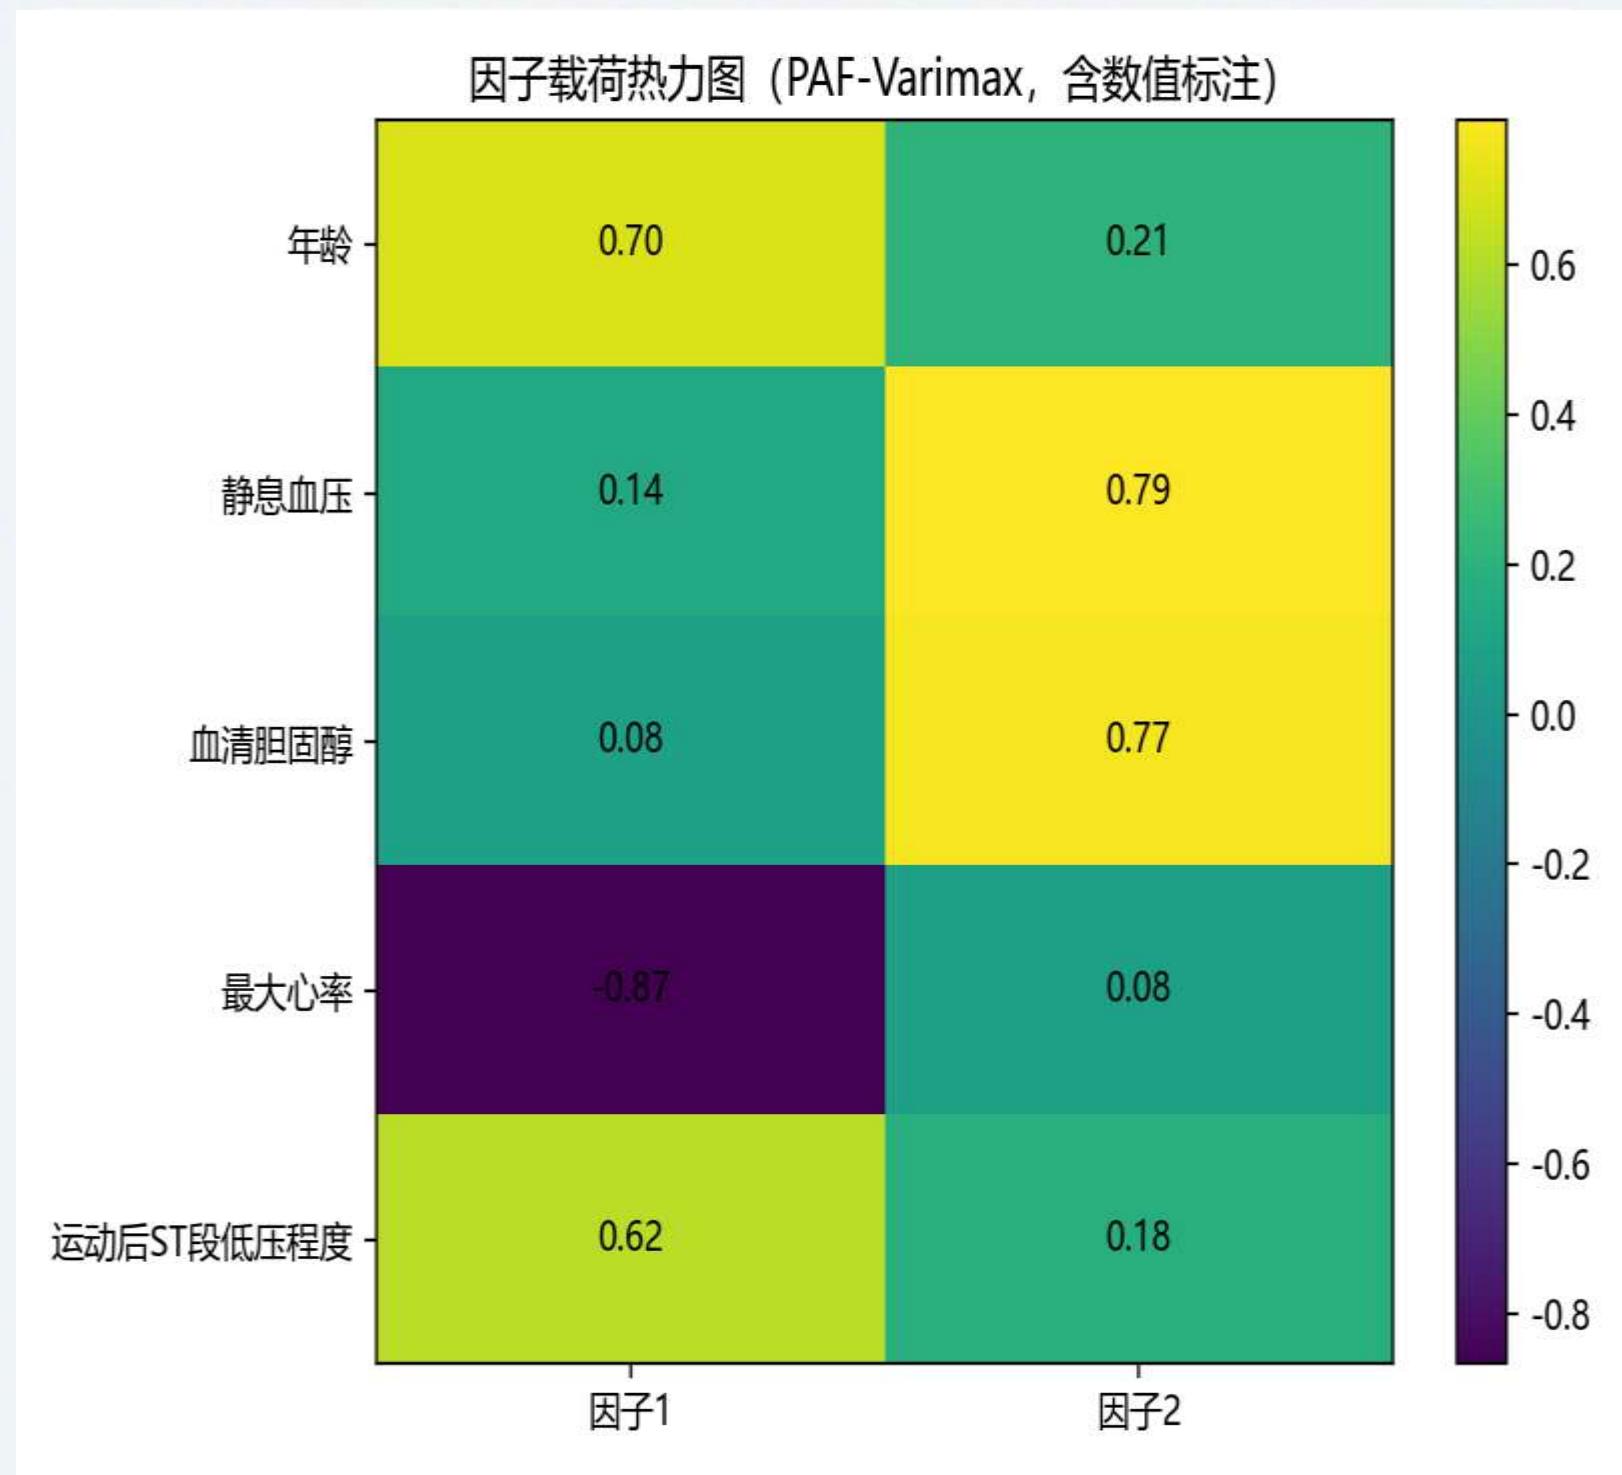


- **目标:** 将多个相关的变量浓缩为少数几个“因子”，以简化数据结构。
- **选择标准:**
  - **Kaiser准则:** 保留特征根(Eigenvalue)  $> 1$  的因子。
  - **碎石图检验:** 在图形“陡坡”与“缓坡”的交界处（拐点）确定因子数量。

---

结论：两种方法均指向保留 2个因子。

# 07/因子解释：从数据到医学含义



## 方法：

采用主轴因子法 (PAF) 提取，并进行方差最大化 (Varimax) 旋转以获得清晰的因子结构。

## 因子1：心功能与运动反应因子

主要负载于“年龄” (0.70), “最大心率” (0.87), “运动后ST段压低” (0.62)。可解释为“年龄越大、运动耐受越差、心肌缺血反应越明显，风险越高”。

## 因子2：基础心血管风险因子

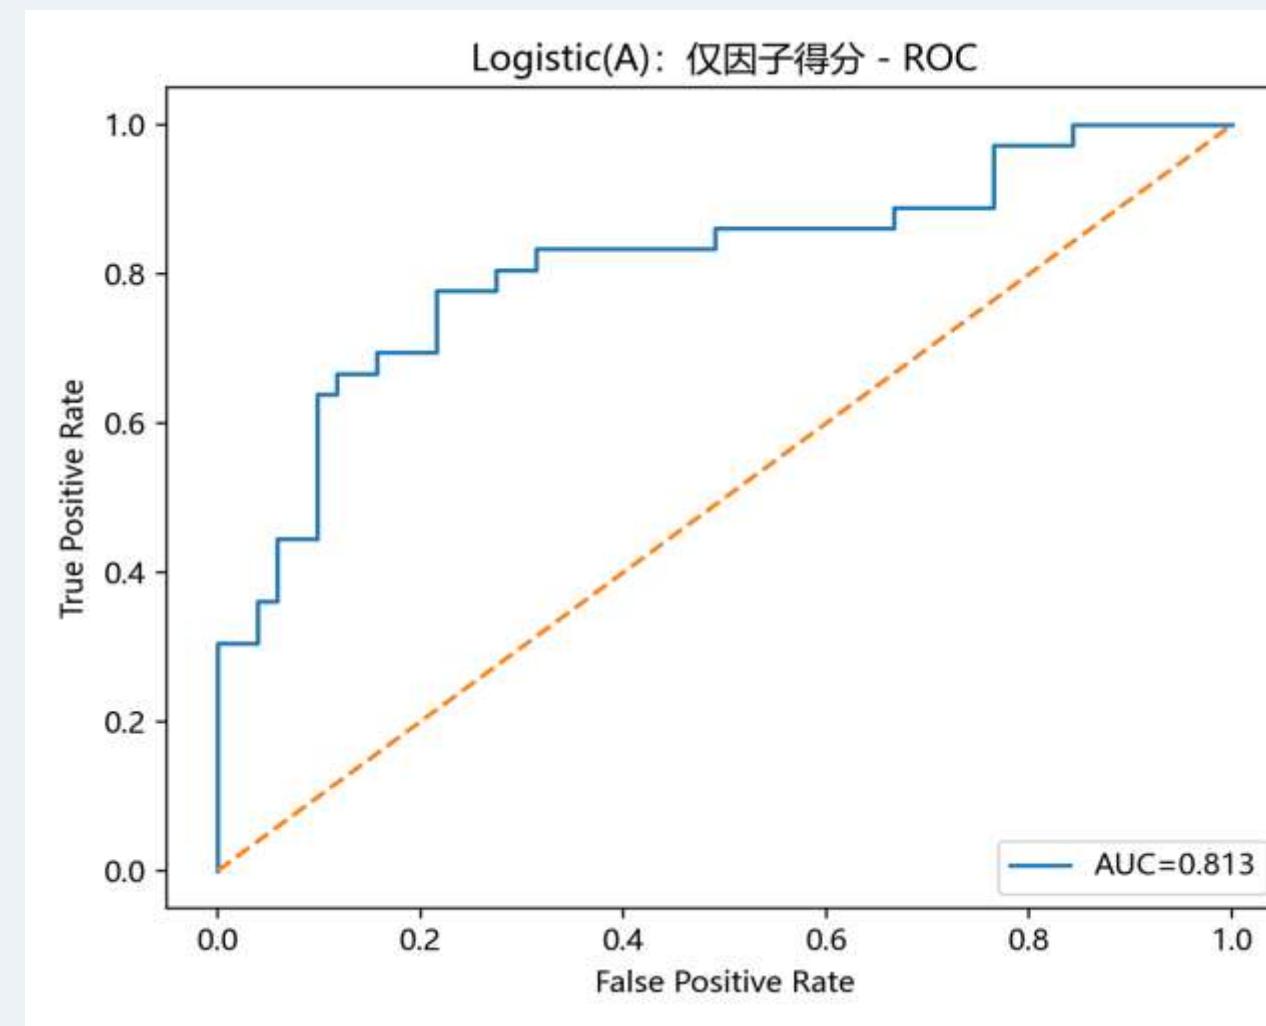
主要负载于“静息血压” (0.79) 和“血清胆固醇” (0.77) 代表了基础的血压与血脂水平风险。

# 08/模型(一): Logistic 回归性能对比

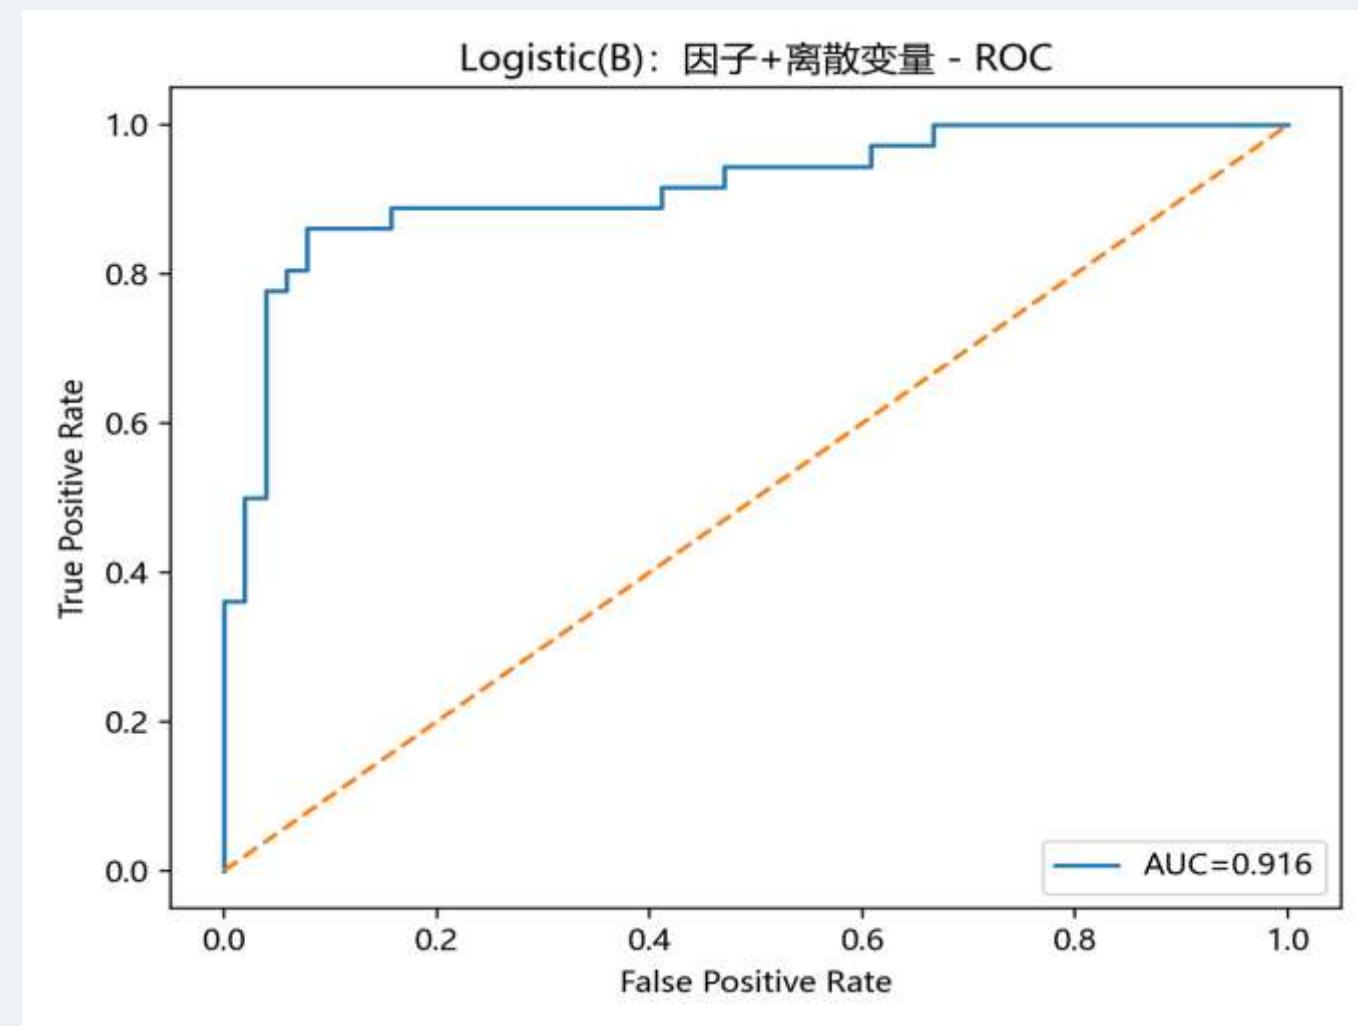
**核心问题:** 仅用2个因子预测(方案A), 和“因子+离散变量”共同预测(方案B), 效果有多大差异?

**结果:** 方案B (因子+离散变量)的预测性能显著优于方案A。

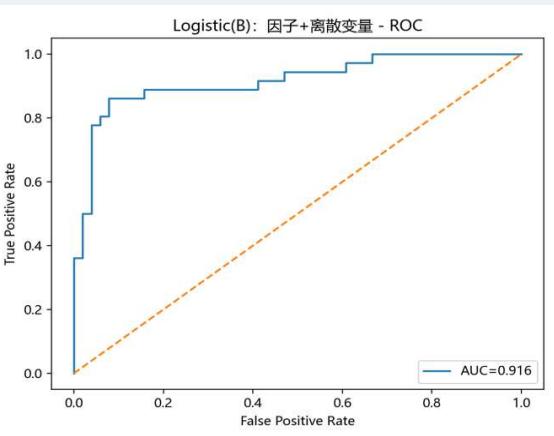
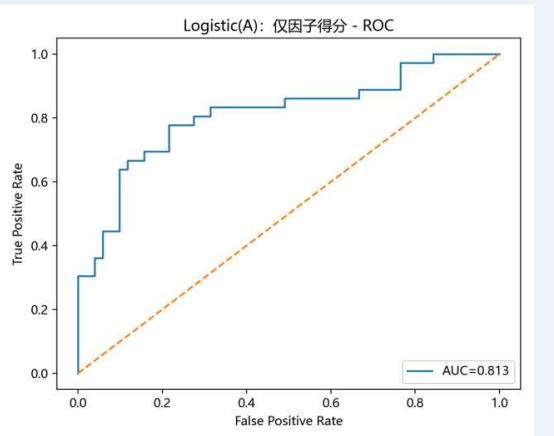
方案A: 仅2个因子



方案B: 因子+离散变量



# 08/模型(一): Logistic 回归性能对比

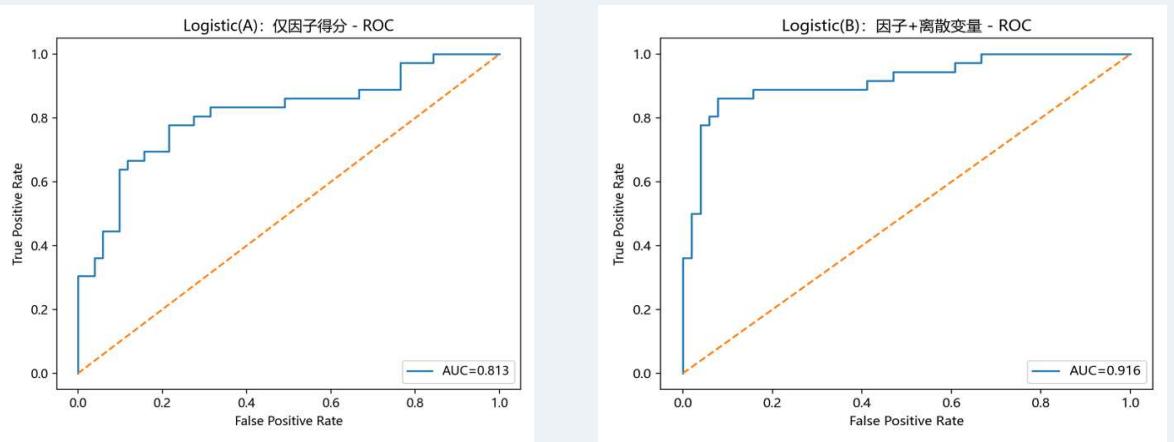


**核心问题:** 仅用2个因子预测(方案A), 和“因子+离散变量”共同预测(方案B), 效果有多大差异?

**结果:** 方案B (因子+离散变量) 的预测性能显著优于方案A。

模型	Test_AUC	Test_ACC	Precision	Recall	F1
Logit_A(仅因子)	0.813	0.770	0.700	0.778	0.737
Logit_B(因子+离散,不含性别)	0.916	0.862	0.816	0.861	0.838

# 08/模型(一): Logistic 回归性能对比



**核心问题:** 仅用2个因子预测(方案A), 和“因子+离散变量”共同预测(方案B), 效果有多大差异?

**结果:** 方案B (因子+离散变量) 的预测性能显著优于方案A。

Logit\_B (因子+离散) 系数Top (展示前12项) :

变量	系数( $\beta$ )
血管堵塞程度_0	-1.5465
胸痛类型_4	1.0293
血管堵塞程度_3	1.0110
铊显像结果_7	0.9922
铊显像结果_3	-0.9073
ST段斜率类型_2	0.6636
因子得分2	0.4545
胸痛类型_1	-0.4479
血管堵塞程度_2	0.4133
因子得分1	0.3749
胸痛类型_2	-0.3533
ST段斜率类型_3	-0.3455

Logit\_A (仅因子) 系数:

变量	系数( $\beta$ )
因子得分1	0.9946
因子得分2	0.5390

注: 系数 $\beta$ 的方向含义:  $\beta > 0$  表示该特征增大/该类别出现时, 患病概率倾向上升;  
 $\beta < 0$  表示倾向下降。离散变量一般经过 One-Hot 编码, 因此系数表示“相对于基准类别”的差异。

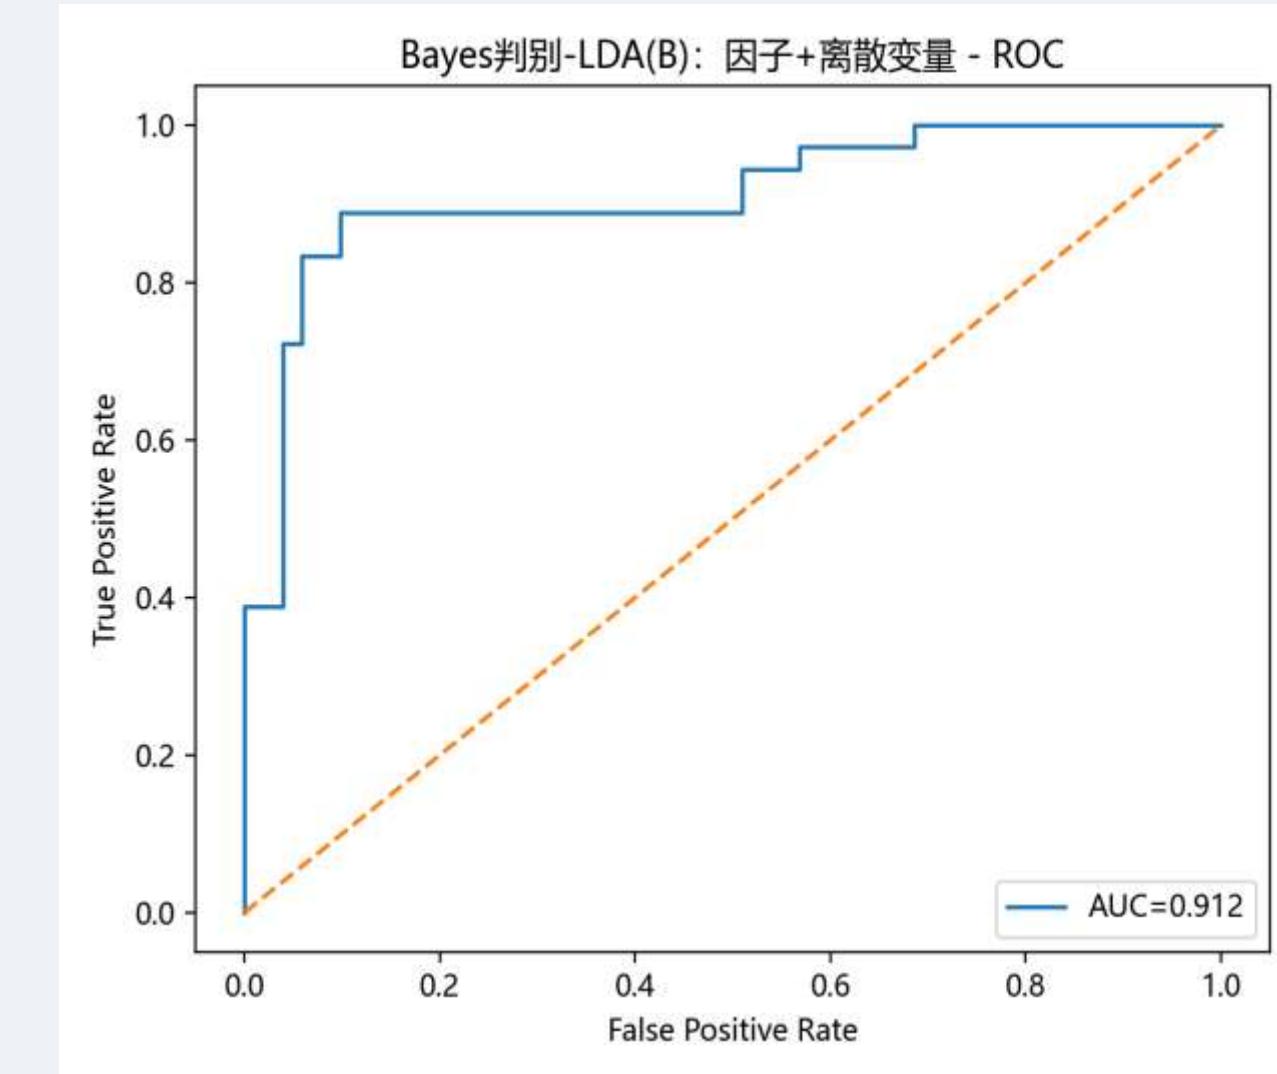
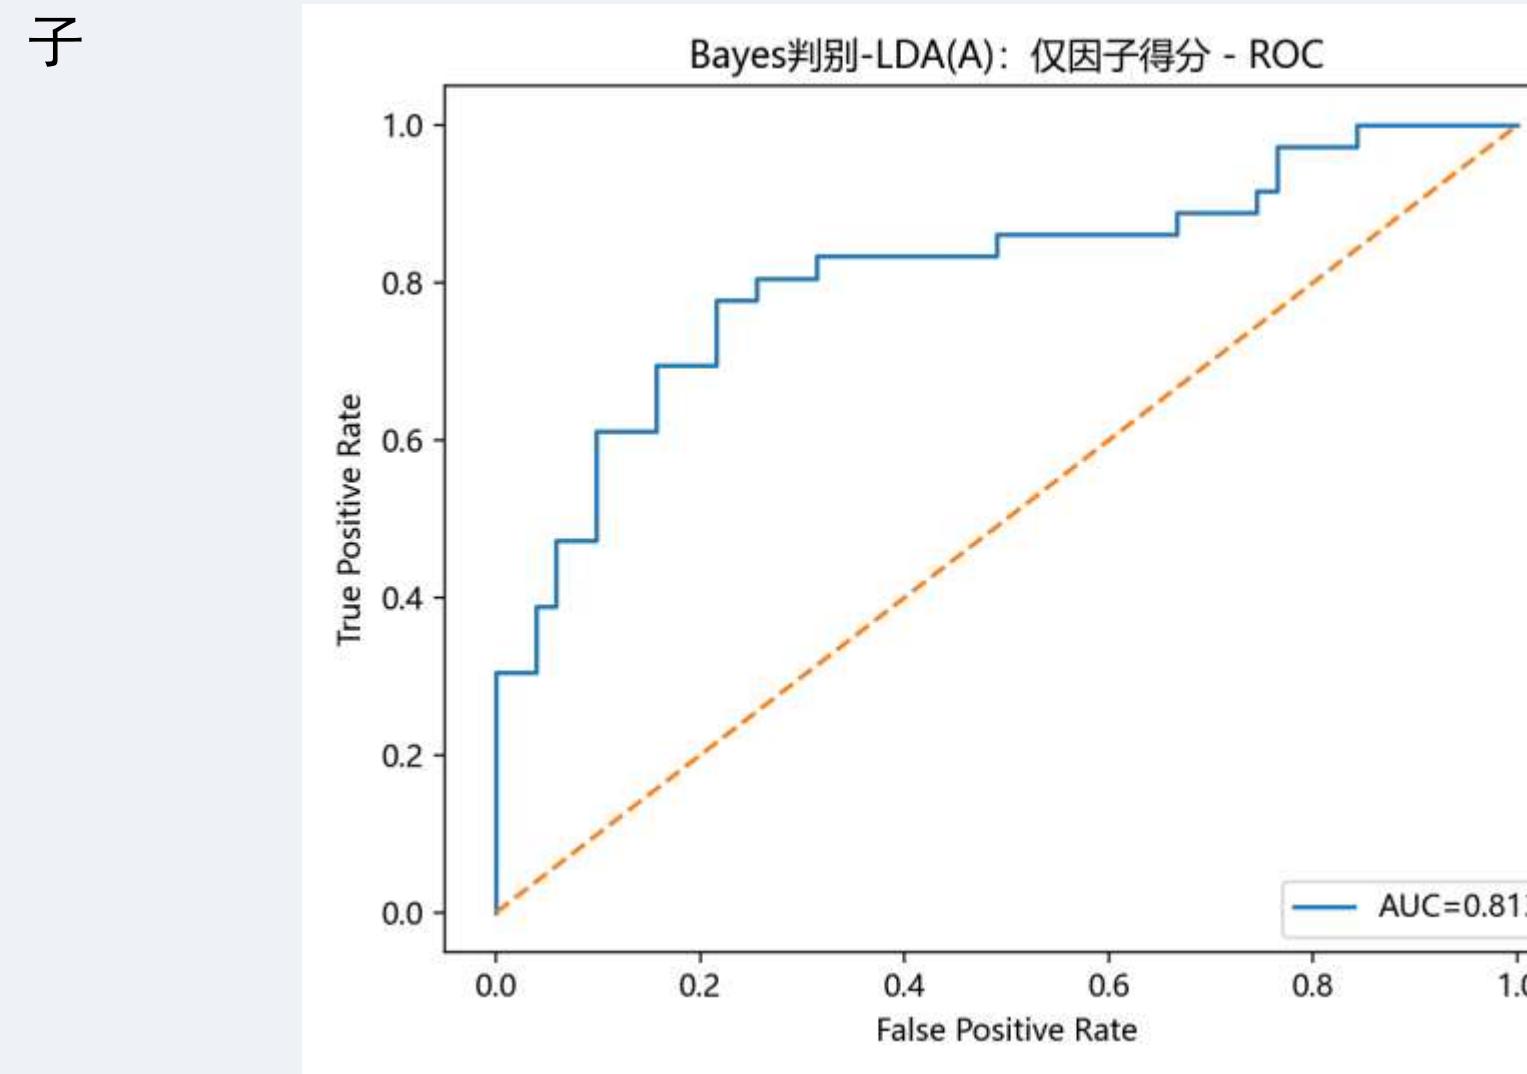
## 09/模型(二)：线性判别分析(LDA) 结果

**目标：**使用另一种经典的线性分类器进行验证，以检验结论的稳健性。

**结果：**LDA的结果与Logistic 回归高度一致。方案B同样表现出色 ( $AUC \approx 0.912$ )，再次证明了增加离散变量的有效性。

方案A：仅2个因

方案B：因子+离散变量

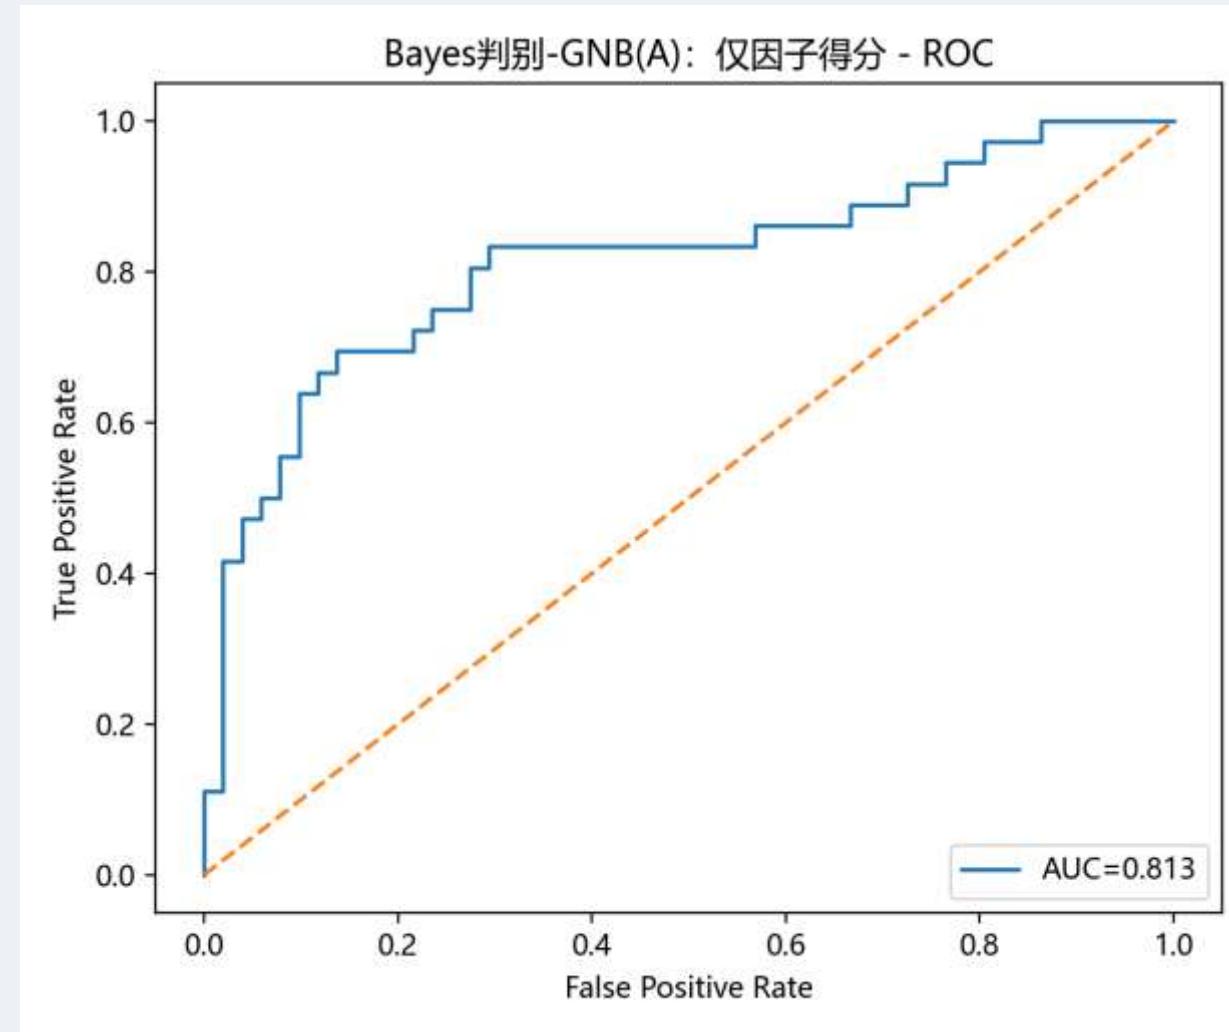


# 10/模型(三)：高斯朴素贝叶斯(GNB) 结果

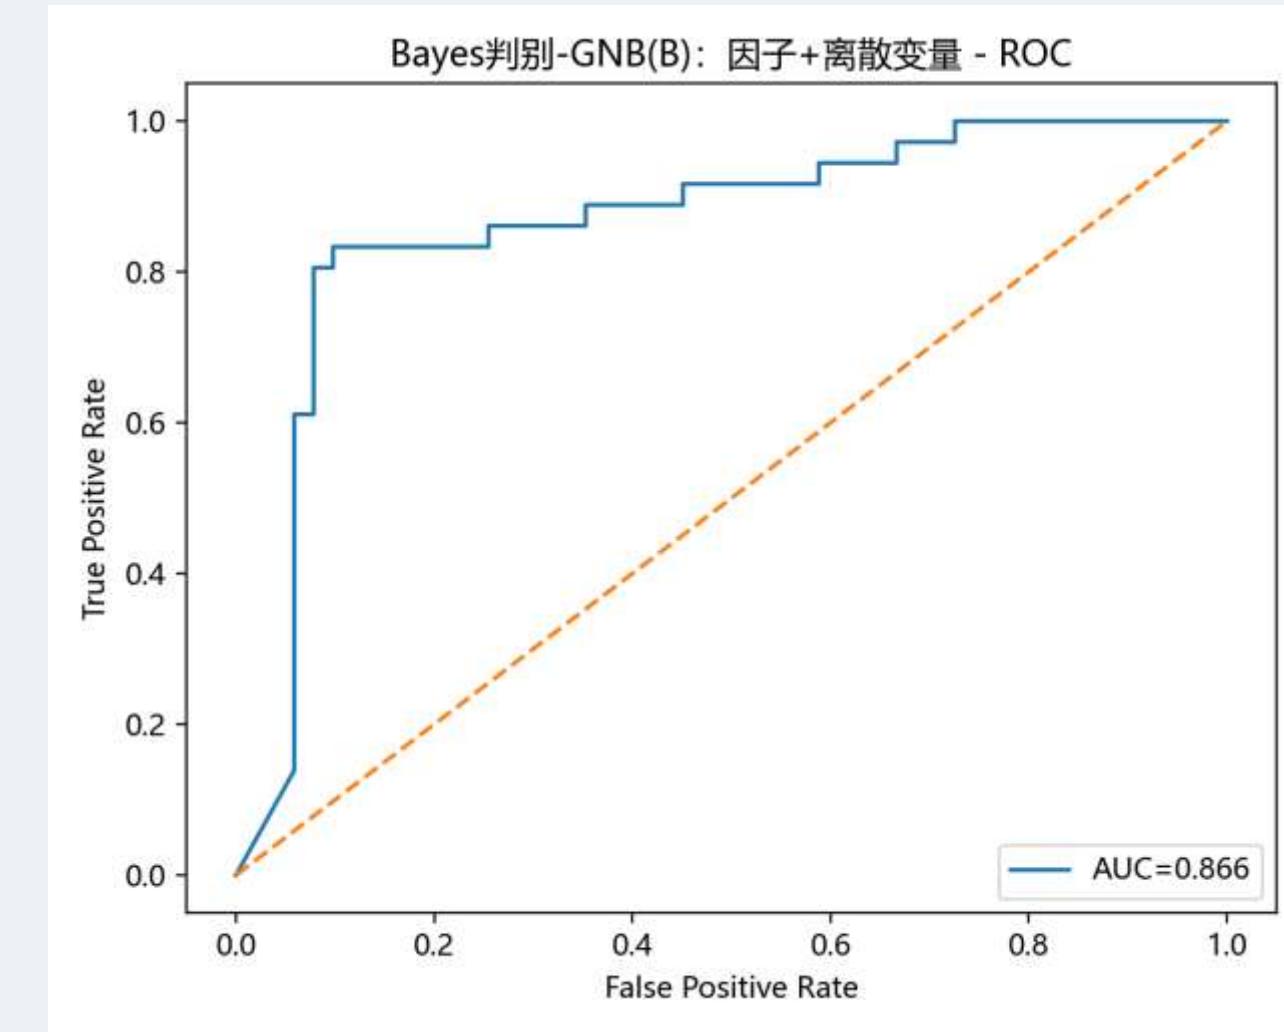
**目标：** 测试基于概率和特征独立性假设的模型。

**结果：** 方案B依然优于方案A，但整体性能 ( $AUC \approx 0.866$ ) 略低于Logistic和LDA。这可能与其较强的“特征独立性”假设有关。

方案A：仅2个因子

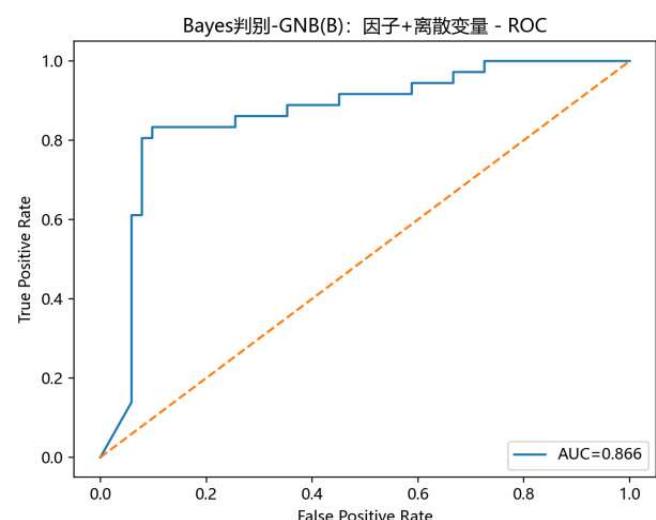
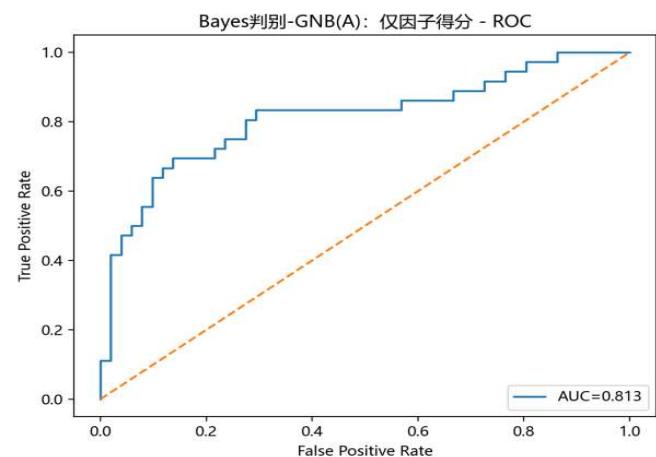
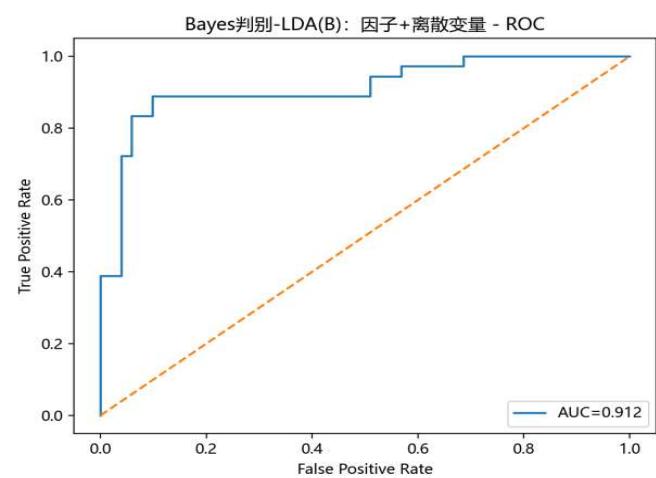
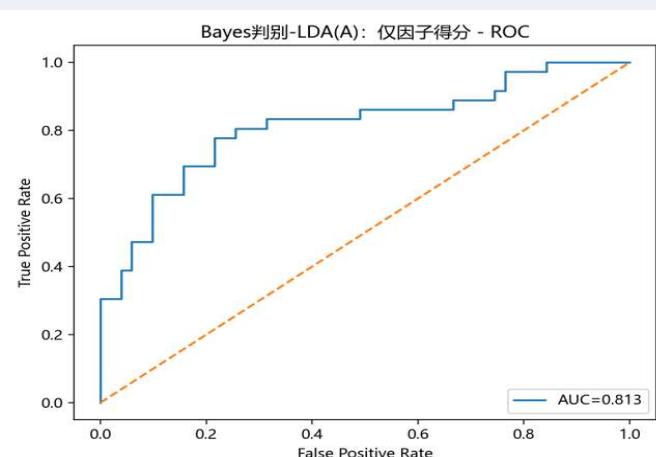


方案B：因子+离散变量



# 11/Bayes判别 (LDA / GNB, 方案A vs 方案B)

模型	Test_AUC	Test_ACC	Precision	Recall	F1
LDA_A(仅因子,按比例先验)	0.813	0.770	0.700	0.778	0.737
LDA_B(因子+离散,按比例先验)	0.912	0.885	0.842	0.889	0.865
GNB_A(仅因子,按比例先验)	0.813	0.736	0.659	0.750	0.701
GNB_B(因子+离散,按比例先验)	0.866	0.782	0.870	0.556	0.678



## 12/综合对比与核心结论

总体发现：在所有模型中，方案B(因子+离散变量)的性能均一致且显著地优于仅使用因子的方案A。

最终结论：Logistic回归模型在方案B下的表现最佳 (AUC=0.916)，是本次分析的最优预测模型。

模型	方案A:仅因子(AUC)	方案B:因子+离散(AUC)	性能提升(B-A)
Logistic回归	0.813	0.916	+0.103
LDA	0.813	0.912	+0.099
高斯朴素贝叶斯	0.813	0.866	+0.053

# 13/一些结论

①年龄偏大的人运动时最大心率较低、运动后心电图 ST 段压低较明显，说明心脏运动耐受能力下降，患病风险更高

②静息血压偏高的人群，心脏病风险更大

在其他条件相近的情况下，静息状态下血压水平越高，心脏长期承受的负荷越大，从而：静息血压偏高往往伴随着更高的心脏病发生风险。

③运动诱发不适症状，提示心脏在负荷下存在隐患

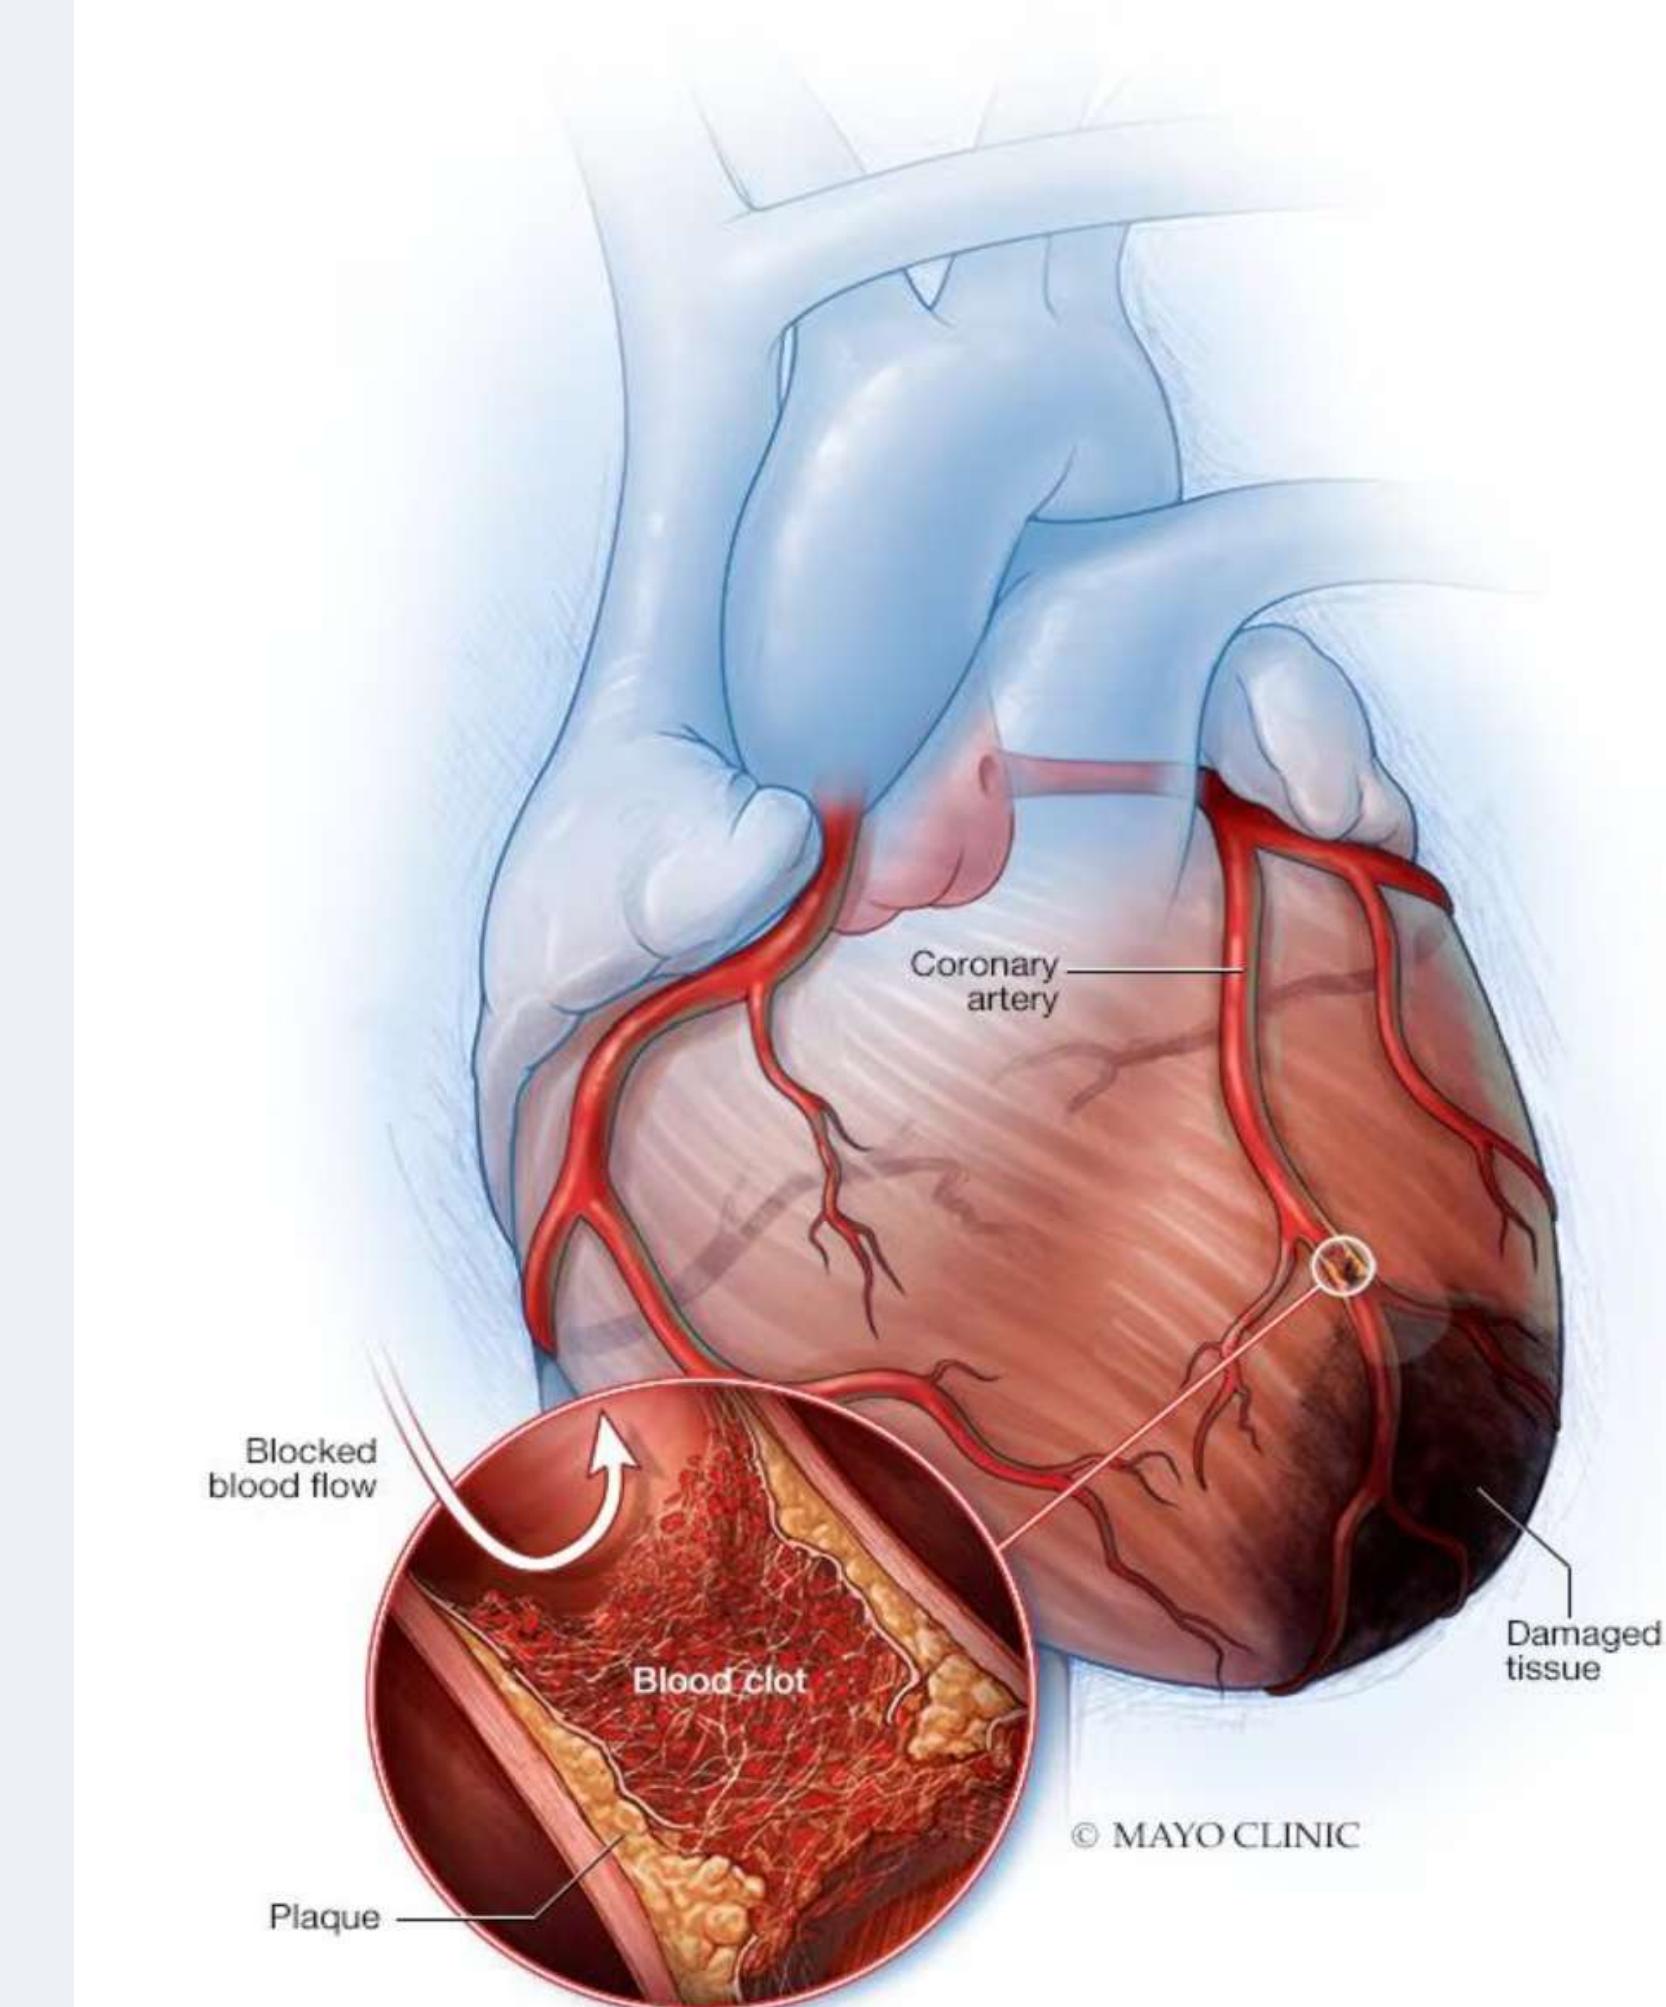
如果个体在运动过程中出现心绞痛或明显不适，通常说明心脏在负荷条件下难以维持正常功能：运动诱发症状的出现，往往与更高的心脏病风险相关。

④多项轻度异常叠加，比单一严重异常更值得警惕

即使单个指标未达到明显异常水平，但多项指标同时处于不利区间时，整体心脏病风险仍会显著上升。这说明心脏病风险更多体现为多因素累积效应，而不是某一个指标“突然失控”。

⑤单一指标作用有限，多项指标联合判断更可靠

无论是连续生理指标，还是离散临床指标，单独使用某一个指标都难以准确判断是否患病。但当多类指标联合考虑时，判断效果显著提升。



# 14/遇到的问题与解决方案



问题1:如何处理混合类型数据进行探索性分析?



解决方案：采用分步策略。先仅对5个连续变量进行聚类和因子分析以挖掘核心结构；再将降维后的因子与原始离散变量结合，构建更全面的预测模型（方案B）。



问题2:如何解决不同变量间的量纲差异?



对连续指标做 Z-score 标准化，保证聚类距离和因子分析的相关结构不会被量纲“绑架”。

## 参考文献：

- [1] Dua D, Graff C. UCI Machine Learning Repository: Heart Disease Data Set[EB/OL]. Irvine, CA: University of California, School of Information and Computer Sciences, 2019. DOI:10.24432/C52P4X.
- [2] Detrano R, Janosi A, Steinbrunn W, et al. International application of a new probability algorithm for the diagnosis of coronary artery disease[J]. The American Journal of Cardiology, 1989, 64(5): 304-310. DOI:10.1016/0002-9149(89)90524-9.  
PubMed
- [3] Ward J H. Hierarchical grouping to optimize an objective function[J]. Journal of the American Statistical Association, 1963, 58(301): 236-244. DOI:10.1080/01621459.1963.10500845.
- [4] Kaiser H F. The application of electronic computers to factor analysis[J]. Educational and Psychological Measurement, 1960, 20(1): 141-151. DOI:10.1177/001316446002000116.
- [5] Cattell R B. The scree test for the number of factors[J]. Multivariate Behavioral Research, 1966, 1(2): 245-276.  
DOI:10.1207/s15327906mbr0102\_10.
- [6] Kaiser H F. The varimax criterion for analytic rotation in factor analysis[J]. Psychometrika, 1958, 23(3): 187-200.  
DOI:10.1007/BF02289233.
- [7] Fisher R A. The use of multiple measurements in taxonomic problems[J]. Annals of Eugenics, 1936, 7(2): 179-188.  
DOI:10.1111/j.1469-1809.1936.tb02137.x.
- [8] Hosmer D W, Lemeshow S, Sturdivant R X. Applied Logistic Regression[M]. 3rd ed. Hoboken, NJ: Wiley, 2013.  
DOI:10.1002/9781118548387.



感谢倾听！请批评指正！

08023110陈奕诚, 08023214张韫译萱, 08023203周一鸣

2025.12.30